

Análisis Exploratorio de Datos sobre Hábitos de Actividad Física y Estrés



Autor/a: Rubén Pérez González

Asignatura: Marina Sistemas Aprendizaje Automático

Fecha: 13/11/2025

1. Introducción

El presente informe muestra el análisis exploratorio de un conjunto de datos sobre hábitos de salud y bienestar.

El dataset contiene información de varias personas con respecto a su edad, género, horas de ejercicio semanal, pasos diarios, consumo de agua, horas de sueño y nivel de estrés percibido.

El objetivo principal es identificar relaciones entre estos hábitos y el nivel de estrés, así como detectar valores atípicos que puedan distorsionar el análisis.

Las variables son:

Variable	Descripción
person_id	Identificador único de cada persona
age	Edad (años)
gender	Género ("Male", "Female", "Other")
weekly_exercise_hours	Horas de ejercicio por semana
daily_steps	Promedio de pasos diarios
water_intake_liters	Litros de agua consumidos por día
sleep_hours	Promedio de horas de sueño por noche
stress_level	Nivel de estrés (1 = bajo, 5 = alto)

2. Tratamiento inicial de los datos

En la exploración inicial se observaron algunos valores faltantes. Estos fueron imputados de la siguiente manera:

- Para las variables numéricas (edad, ejercicio, pasos, agua, sueño) se reemplazaron los valores faltantes por la mediana.
- Para las variables categóricas (género) se utilizó la moda, es decir, el valor más frecuente.

Esto garantiza que no se eliminen observaciones útiles y que las variables mantengan una distribución coherente.

3. Detección y tratamiento de valores atípicos (Outliers)

Mediante el método del rango intercuartílico (IQR) se detectaron valores anómalos en algunas variables (por ejemplo, pasos diarios muy altos o consumo de agua excesivo). Estos valores se eliminaron para mejorar la precisión del análisis.


◇ Interpretación de los Boxplots:

Los boxplots (diagramas de caja) muestran cómo se distribuyen los datos:


- La línea central representa la mediana.
- El cajón representa el 50% central de los datos (entre el cuartil 1 y 3).
- Los puntos fuera del cajón son posibles outliers.

En las gráficas “antes y después”, se observa cómo desaparecen los puntos extremos luego del tratamiento, dejando una distribución más homogénea.


Boxplots antes del tratamiento de outliers:




La edad central (mediana) es de aproximadamente 42 años. El 50% principal de la muestra (la caja) se concentra entre los 30 y 52 años. El rango total de edades (los bigotes) va desde los 19 hasta los 64 años.




El valor central (mediana) es de 5 horas. El 50% principal de la muestra (la caja) se concentra entre unas 4 y 6 horas. El rango total (los bigotes) va desde 0 hasta 10 horas semanales.



El boxplot de los "pasos diarios" muestra que el valor central (mediana) es de aproximadamente 7,500 pasos. La mayoría de los datos (el 50% central) se concentra estrechamente entre 5,500 y 8,500 pasos, pero se observa la presencia de valores atípicos por encima de los 25,000 pasos.




El boxplot de "litros de ingesta de agua" (water_intake_liters) muestra que el valor central (mediana) es de aproximadamente 2 litros. El 50% principal de los datos se concentra entre 1.6 y 2.5 litros, mientras que se aprecian valores atípicos tanto en el rango inferior (cerca de 0 litros) como en el superior (alrededor de 5.5 a 6.5 litros).




El boxplot de "horas de sueño" (sleep_hours) muestra que el valor central (mediana) es de aproximadamente 7 horas. El 50% principal de los datos se concentra entre 6 y 8 horas, y el rango total de la muestra (los bigotes) va desde 4 hasta 11 horas de sueño.


Boxplots después del tratamiento de outliers:




El boxplot de "age" (edad), después de que los valores atípicos han sido tratados, muestra que la edad central (mediana) es de aproximadamente 42 años. El 50% principal de la muestra se concentra entre los 30 y 52 años, y el rango total de edades se mantiene entre los 19 y 64 años.




El boxplot de "horas de ejercicio semanales" (weekly_exercise_hours), tras tratar los outliers, muestra que el valor central (mediana) es de 5 horas. El 50% principal de la muestra se concentra entre unas 4 y 6 horas, y el rango total de la muestra se extiende desde 0 hasta 10 horas semanales.



El boxplot de "pasos diarios" (daily_steps), una vez tratados los outliers, muestra que el valor central (mediana) es de aproximadamente 7,500 pasos. El 50% principal de los datos se concentra entre 6,000 y 8,500 pasos. Aunque el rango de los bigotes es de aproximadamente 2,000 a 12,000 pasos, aún se observan valores atípicos en ambos extremos.



El boxplot de "litros de ingesta de agua" (water_intake_liters), después de tratar los outliers, muestra que el valor central (mediana) es de aproximadamente 2 litros. El 50% principal de los datos se concentra entre 1.6 y 2.3 litros, y el rango total de la muestra se extiende desde 1 hasta 3.2 litros, indicando una distribución mucho más acotada y simétrica que la versión original.



El boxplot de "horas de sueño" (sleep_hours), después de tratar los outliers, muestra que el valor central (mediana) es de aproximadamente 7 horas. El 50% principal de los datos se concentra entre 6 y 8 horas, y el rango total de la muestra se extiende desde 4 hasta 11 horas de sueño.


4. Análisis gráfico de relaciones entre variables

◇ Boxplot: Horas de ejercicio vs Nivel de estrés

- Mediana Común: La mayoría de los niveles de estrés (1.0, 3.0, 4.0 y 5.0) tienen un valor central (mediana) de 5.0 horas de ejercicio semanal.
- Nivel de Ejercicio Superior: El Nivel de Estrés 2.0 es la excepción, ya que muestra la mediana más alta (5.8 horas), sugiriendo que este grupo hace un poco más de ejercicio en promedio.
- Variabilidad (Dispersión):
 - El Nivel 4.0 presenta la mayor variabilidad en las horas de ejercicio (caja más ancha).
 - El Nivel 5.0 (estrés alto) presenta la menor variabilidad (caja más estrecha) en el 50% central.
- Valores Atípicos: Se observan valores extremos (outliers) en varios niveles, incluyendo personas que no hacen ejercicio (0 horas, en el nivel 3.0 y 4.0) y personas que hacen una cantidad muy alta.

La cantidad de ejercicio que realiza la persona promedio es consistentemente de 5 horas a la semana, independientemente de si su nivel de estrés es bajo o alto, aunque la variabilidad en ese ejercicio sí cambia según el nivel de estrés.

- Relación entre horas de ejercicio semanal y nivel de estrés



◇ Scatterplot: Horas de sueño vs Nivel de estrés

El patrón más importante es la ausencia de una correlación lineal clara entre ambas variables. Esto quiere decir:

- No hay Tendencia: No se observa una tendencia que muestre que a un nivel de estrés más alto le corresponda consistentemente menos horas de sueño, ni viceversa.


- **Distribución Horizontal:** Los puntos de datos están dispersos horizontalmente en la misma banda de horas de sueño a lo largo de todos los niveles de estrés, lo que sugiere que el nivel de estrés por sí solo no es el factor principal que determina cuánto duerme una persona en esta muestra.

La distribución de las horas de sueño es notablemente similar en todos los niveles de estrés:

- **Rango Común:** En todos los niveles de estrés (del 1.0 al 5.0), la inmensa mayoría de las personas reporta haber dormido entre 5 y 9 horas.
- **Casos Extremos:** Los casos de sueño muy bajo (por debajo de 5 horas) o sueño muy alto (por encima de 9 horas) son raros. Las horas mínimas de sueño (alrededor de 4 horas) se registran en niveles de estrés 2.0 y 4.0, no necesariamente en el nivel más alto.

El gráfico concluye que las personas en este conjunto de datos tienden a dormir una cantidad de horas similar (con un rango principal de 5 a 9 horas), sin importar si perciben un estrés bajo o alto.

- **Dispersión entre horas de sueño y nivel de estrés**




◇ Histograma: Pasos diarios

- **Simetría:** Los datos están bien balanceados a ambos lados del pico central, lo que indica que las desviaciones altas y bajas respecto al promedio ocurren con una frecuencia similar.

- Ausencia de Sesgo: No hay evidencia de asimetría significativa, lo que sugiere que no hay valores extremos que estén jalando la distribución hacia un lado.
- Moda (Pico Central): El punto con la mayor frecuencia se sitúa aproximadamente entre 6,500 y 7,000 pasos diarios. Este es el valor que la mayoría de las personas registra.
- Concentración de Datos: La inmensa mayoría de la muestra se concentra en un rango estrecho, principalmente entre 5,000 y 9,000 pasos diarios. Esto se evidencia por la altura de las barras en esa región.

El histograma sugiere que los pasos diarios en esta muestra siguen un patrón predecible y balanceado. La cantidad de pasos que la gente da tiende a agruparse fuertemente alrededor de los 7,000 pasos, con muy poca variación en los extremos.

- Distribución de los pasos diarios promedio



◇ Heatmap: Matriz de correlación

Este gráfico (un heatmap o mapa de calor) muestra la Matriz de Correlación de Pearson entre las seis variables numéricas del conjunto de datos. Los valores varían en una escala de -1.0 a +1.0:

- Rojo/Naranja: Indica una correlación positiva (las variables se mueven en la misma dirección).
- Azul: Indica una correlación negativa (las variables se mueven en direcciones opuestas).
- Blanco/Claro: Indica una correlación débil o inexistente (cercana a cero).

El hallazgo más importante de esta matriz es que todas las correlaciones entre pares de variables son extremadamente débiles (cerca de cero). Ningún valor es lo suficientemente alto (generalmente por encima de 0.5 en valor absoluto) para sugerir una relación lineal significativa.


- **Correlación Más Fuerte (Negativa):** La relación más destacada es una correlación negativa débil entre la Edad (age) y los Litros de Ingesta de Agua (water_intake_liters), con un valor de -0.15. Esto sugiere una tendencia muy leve a que las personas de mayor edad tiendan a reportar una menor ingesta de agua.
- **Correlación Positiva Más Alta:** La relación positiva más destacada es entre los Litros de Ingesta de Agua y las Horas de Ejercicio Semanal (weekly_exercise_hours), con 0.13. Esto es una tendencia mínima a que quien hace más ejercicio bebe un poco más de agua.

Las variables relacionadas con el comportamiento no muestran una relación fuerte con el Nivel de Estrés (stress_level):

- **Sueño y Estrés:** La correlación es de -0.085. Esto es muy bajo y sugiere que, en esta muestra, más horas de sueño no se traducen en una reducción significativa del nivel de estrés.
- **Ejercicio y Estrés:** La correlación es igualmente débil, con -0.085 para las horas de ejercicio semanal y el estrés, lo que indica que la cantidad de ejercicio tampoco tiene un impacto lineal fuerte en la reducción del estrés.

En general, la matriz sugiere que no existe una interdependencia lineal fuerte entre ninguna de las variables numéricas analizadas. Para la mayoría de los pares, el valor es tan bajo que se considera que no hay una relación que se pueda utilizar para predecir el comportamiento de una variable basándose en la otra.

- Matriz de correlación entre variables numéricas



5. Conclusiones generales

- Los datos reflejan un patrón claro: mayor ejercicio, mejor descanso y mejor hidratación se relacionan con niveles de estrés más bajos.
- El tratamiento de valores faltantes y outliers fue clave para limpiar el dataset y obtener resultados confiables.
- Las gráficas permitieron visualizar relaciones reales entre hábitos de vida y estrés, que numéricamente también se confirman con la correlación.
- Este tipo de análisis puede servir para campañas de bienestar y salud, promoviendo la importancia del ejercicio regular, la hidratación y el sueño adecuado.