


Random Forest



Autores: Rubén Pérez González, Miguel Ruiz Merino

Fecha: 11/02/2026

Asignatura: Sistemas de Aprendizaje Automático (IA)

1. Comparación de Accuracy

Accuracy arbol de decision:

accuracy	0.66	540
----------	------	-----

Accuracy random forest

accuracy	0.98	540
----------	------	-----

Resultados: Árbol de Decisión (0.66) | Random Forest (0.98).

¿Cuál es mayor? El Random Forest es significativamente superior.

¿Era esperable? Sí. Un solo árbol sufre de alta varianza (se confunde con detalles irrelevantes), mientras que el Random Forest promedia las decisiones de muchos árboles, filtrando el error.

En producción, un modelo del 66% sería inaceptable (fallaría 1 de cada 3 veces). El Random Forest ofrece la estabilidad necesaria para una aplicación real.

2. Análisis del Classification Report

Clasificación Árbol de Decisión

Informe de Clasificación:				
	precision	recall	f1-score	support
0	1.00	0.89	0.94	53
1	0.50	0.16	0.24	50
2	0.52	0.26	0.34	47
3	0.45	0.83	0.58	54
4	0.80	0.80	0.80	60
5	0.97	0.85	0.90	66
6	0.85	0.94	0.89	53
7	0.83	0.69	0.75	55
8	0.32	0.81	0.46	43
9	0.81	0.29	0.42	59
accuracy			0.66	540
macro avg	0.70	0.65	0.63	540
weighted avg	0.72	0.66	0.65	540

Clasificación Random Forest


REPORTE CLASIFICACIÓN - RANDOM FOREST					
		precision	recall	f1-score	support
	0	1.00	0.98	0.99	53
	1	0.96	1.00	0.98	50
	2	1.00	1.00	1.00	47
	3	0.98	0.96	0.97	54
	4	0.97	1.00	0.98	60
	5	0.97	0.95	0.96	66
	6	0.98	0.98	0.98	53
	7	0.98	0.98	0.98	55
	8	0.95	0.95	0.95	43
	9	0.97	0.95	0.96	59
	accuracy			0.98	540
	macro avg	0.98	0.98	0.98	540
	weighted avg	0.98	0.98	0.98	540

¿Mejoran las métricas? Sí, de forma drástica. El dígito "1" pasó de un recall de 0.16 a 1.00. Esto significa que el árbol individual era incapaz de identificar la mayoría de los "unos", mientras que el Random Forest los identifica todos.

Dígito problemático: En el Random Forest, el 8 tiene la precisión más "baja" (0.95), indicando que es el más propenso a confundirse levemente.

Los dígitos con muchas curvas o que encierran espacios (como el 8) pueden parecerse a otros (como el 0 o el 9) si el trazo es ambiguo.

3. Matriz de Confusión del Random Forest



Análisis: Se observa una diagonal limpia y con valores altos (colores oscuros), lo que indica una precisión excelente. Por ejemplo, el modelo acertó 63 veces al clasificar el número 5 y 60 veces el número 4.

Las confusiones masivas que solían aparecer con el árbol individual han desaparecido casi por completo. Sin embargo, mirando la gráfica en detalle, aún se detectan leves errores:

El dígito 8: El modelo lo confundió con un 1 en 2 ocasiones (Fila 8, Columna 1).

El dígito 3: Se confundió con un 8 en 2 ocasiones (Fila 3, Columna 8).

El dígito 9: Tuvo 3 errores dispersos (confundido con 3, 5 y 7).

Los errores que persisten (como esos dos "8" que parecen "1") ya no suelen ser culpa de la falta de capacidad del modelo, sino que probablemente se deben a "ruido" en la imagen original. Es muy probable que esos dígitos específicos estén tan mal escritos o sean tan ambiguos que incluso un humano dudaría al intentar clasificarlos. El Random Forest ha llegado al límite de lo que es distinguible lógicamente.

4. Robustez del Random Forest

¿Por qué es menos sensible? El Random Forest utiliza una técnica llamada Bagging (Bootstrap Aggregating). Mientras que un solo árbol se ajusta de forma rígida a todos los datos de entrenamiento (pudiendo aprenderse errores o ruido), el Random Forest crea muchos árboles sobre subconjuntos aleatorios de los datos. Si un pequeño grupo de datos cambia o es erróneo, solo afectará a unos pocos árboles, y el voto de la mayoría del bosque corregirá ese error.

Esta robustez es fundamental en el diagnóstico médico por imagen. Si una radiografía tiene una pequeña mancha o ruido técnico, no queremos que el modelo cambie drásticamente su diagnóstico. También es crítica en la detección de fraudes bancarios, donde los datos de las transacciones pueden variar constantemente y necesitamos un modelo estable que no dé falsas alarmas ante cambios mínimos en el comportamiento del usuario.

5. Parámetro `n_estimators`


¿Qué significa? En mis propias palabras, `n_estimators` es el número de "expertos" (árboles) que componen nuestro bosque. Es la cantidad de modelos individuales que consultaremos antes de dar una respuesta final.

Si usas solo 5 árboles: El modelo será muy rápido de entrenar, pero su precisión será baja y será inestable. Es como pedirle consejo a solo 5 personas; si dos de ellas se equivocan, la decisión final será probablemente incorrecta.

Si usas 500 árboles: El modelo se vuelve muy robusto y preciso, pero el proceso de entrenamiento y el uso de memoria RAM serán mucho más pesados.

Sí, existe un punto de saturación. Pasar de 10 a 100 árboles suele dar un salto de precisión enorme (como vimos en tus imágenes de 66% a 98%), pero pasar de 500 a 1000 apenas mejora unas milésimas el accuracy. En ese punto, solo estamos gastando energía y tiempo de computación sin obtener beneficios reales.

6. Importancia de Variables (Píxeles)



Análisis de la gráfica: La imagen muestra una matriz de 8x8 que representa los 64 píxeles de cada imagen de entrada. El código de colores indica cuánto peso tiene cada píxel en la decisión final del Random Forest:

Zonas Claras (Amarillo/Blanco): Representan los píxeles con mayor importancia (valores superiores a 0.03 o 0.04). Se concentran claramente en el centro de la cuadrícula.

Zonas Oscuras (Negro/Rojo oscuro): Representan una importancia nula o muy baja (cercana a 0.00). Corresponden a los bordes de la imagen.

¿Por qué unos son más importantes? La razón física es que los píxeles centrales son los que forman la silueta del número. En este dataset, los dígitos están centrados; por tanto, los píxeles de los bordes (el marco exterior) casi siempre están vacíos (valor 0 o fondo), independientemente de si el número es un "1" o un "9". Al no variar, el modelo

aprende a ignorarlos porque no aportan información para clasificar (ganancia de información nula).

Basándonos en esta gráfica, sí podríamos reducir la dimensionalidad. Podríamos eliminar todos los píxeles del marco exterior (las zonas negras) sin afectar al rendimiento del modelo. Esto reduciría la entrada de 64 características a quizás 30 o 40.

Ventaja: El modelo sería más ligero y rápido de entrenar y ejecutar (útil en dispositivos móviles o sistemas en tiempo real).

Riesgo: Si en el futuro entran datos donde los números no estén perfectamente centrados, el modelo fallaría al haber ignorado los bordes.

7. Visualización y Estrategia

¿Es posible visualizarlo completo? No, porque un Random Forest son cientos de árboles trabajando a la vez. No es una sola estructura lógica simple.

Estrategia: Para explicarlo, usaría la gráfica de "Importancia de Variables" para mostrar qué partes del número mira el algoritmo.

8. Interpretabilidad vs Rendimiento

Preferencia: Random Forest.

En este caso, la diferencia de precisión (de 66% a 98%) es demasiado grande para ignorarla. La pérdida de interpretabilidad se compensa con un sistema casi infalible.

9. Aplicaciones reales

¿En qué problemas usarlo? Lo usaría en cualquier problema donde los datos sean complejos y no sigan una estructura lineal simple, como la predicción de fuga de clientes (Churn) en una empresa de telefonía o el análisis de riesgo de crédito.

Ventaja de Random Forest: Un solo árbol podría decidir que cualquier correo con la palabra "Premio" es spam. Un Random Forest analizará múltiples combinaciones de palabras y metadatos en cientos de árboles. Esto evita que correos importantes (como un premio legítimo de una beca universitaria) se pierdan, ya que el bosque considerará otros factores que un solo árbol ignoraría por ser demasiado simplista.

10. Explicación para no técnicos

Es como consultar a un comité de 100 expertos donde cada uno analiza una parte distinta del dibujo y luego votan para decidir qué número es. Esto evita que el error de un solo experto arruine el resultado.