

Predicción con Naive Bayes

F Ó R M U L A N A I V E B A Y E S

$$P(A|R) = \frac{P(R|A)P(A)}{P(R)}$$

$P(A)$: Probabilidad de A

$P(R|A)$: Probabilidad de que se de R dado A

$P(R)$: Probabilidad de R

$P(A|R)$: Probabilidad posterior de que se de A dado R

Autor: Rubén Pérez González

Fecha: 14/01/2026

Asignatura: Sistemas de Aprendizaje Automático (IA)

1. Carga y exploración de datos

Número de observaciones: 178 muestras.

Número de variables: 13 variables predictoras y 1 variable objetivo.

Variables predictoras: Todas son de tipo numérico continuo (float64), lo cual es ideal para el modelo Gaussian Naive Bayes que asume distribuciones normales.


Variable objetivo: Es de tipo categórico (codificada como enteros 0, 1 y 2).

Distribución de la variable objetivo:

Clase 0: 59 muestras.

Clase 1: 71 muestras.

Clase 2: 48 muestras.



Escalabilidad y Volumen: El dataset cuenta con apenas 178 registros para 13 variables. Esta baja relación entre el número de muestras y variables sugiere que el modelo debe ser sencillo para evitar el sobreajuste (overfitting). Naive Bayes es una elección acertada aquí, ya que funciona bien con conjuntos de datos pequeños gracias a su suposición de independencia.

Desequilibrio de clases: Existe un desequilibrio moderado entre la Clase 1 (la más frecuente con un 40%) y la Clase 2 (la menos frecuente con un 27%). Aunque no es un desequilibrio crítico, es suficiente para que el modelo aprenda mejor los patrones de la Clase 1.

Implicaciones en la evaluación: Debido a este desequilibrio, la métrica de Accuracy podría ser ligeramente engañosa. Será fundamental analizar la Precision y el Recall de la Clase 2 en los resultados finales, ya que es la clase que el modelo tiene "menos oportunidades" de estudiar durante el entrenamiento.

2. Preprocesamiento

¿Por qué tiene sentido escalar los datos? Tiene sentido debido a la gran disparidad en las magnitudes de las variables del dataset Wine. Por ejemplo, la variable proline tiene valores en el rango de los cientos o miles, mientras que nonflavanoid_phenols presenta valores inferiores a 1. El escalado equilibra la contribución relativa de cada variable; sin él, las variables con rangos numéricos elevados podrían sesgar el análisis de varianza, dificultando que el modelo identifique correctamente la importancia de aquellas variables con escalas pequeñas pero con alto poder predictivo.

¿Es obligatorio para Naive Bayes? No, no es estrictamente obligatorio para el modelo GaussianNB. Este algoritmo estima la probabilidad de cada clase asumiendo una distribución normal y tratando cada característica de forma independiente. Dado que el cálculo se basa en la media y desviación estándar de cada variable por separado, las suposiciones probabilísticas no varían con el escalado. Sin embargo, en esta práctica se realiza para garantizar la estabilidad numérica y permitir una comparación técnica coherente con otros modelos que sí lo requieren.

3. Entrenamiento del modelo

Porcentaje de datos para entrenamiento y test: Se ha utilizado un 80% de los datos para el conjunto de entrenamiento (142 muestras) y un 20% de los datos para el conjunto de test (36 muestras).


Justificación de la elección: Esta proporción (80/20) se ha seleccionado para maximizar el aprendizaje del modelo en un dataset de tamaño reducido (178 muestras totales). Al reservar un 20% para test, aseguramos un número suficiente de ejemplos (36) para obtener métricas de evaluación estadísticamente representativas sin sacrificar la capacidad del algoritmo para capturar la variabilidad de las tres clases de vino durante la fase de entrenamiento.

4. Evaluación

¿Qué clase predice mejor? La Clase 2 es la que presenta un rendimiento perfecto, con un valor de 1.00 en todas las métricas (Precision, Recall y F1-Score). Esto indica que el modelo identifica esta variedad de vino sin ninguna confusión.

¿Hay más falsos positivos o falsos negativos? Existe un equilibrio técnico derivado de un único error: hay un falso positivo en la Clase 0 (se predijo Clase 0 siendo Clase 1) y un falso negativo en la Clase 1 (no se detectó correctamente). El impacto es idéntico para ambos conceptos.

¿Es suficiente la accuracy? Sí, en este caso es un indicador fiel. Aunque la accuracy es del 97.22%, su validez se confirma porque el F1-Score es superior a 0.96 en todas las clases, lo que demuestra que el alto acierto no se debe a un sesgo por desequilibrio de clases, sino a un buen desempeño general.



Resultados: La matriz muestra una diagonal principal casi perfecta. El único error (1 muestra) consiste en clasificar un vino de la Clase 1 como Clase 0. Esto refleja un ligero solapamiento en las propiedades químicas entre estas dos clases, mientras que la Clase 2 es totalmente distinguible.

Clase	Precision	Recall	F1-Score	Support
class_0	0.92	1.00	0.96	12
class_1	1.00	0.93	0.96	14
class_2	1.00	1.00	1.00	10
Accuracy			0.97	36

Gravedad de los errores: El error detectado es leve, pero en un entorno comercial, confundir categorías de vino podría afectar la confianza del consumidor si los estándares de calidad difieren entre la Clase 1 y la Clase 0. La Clase 1 se identifica como la más compleja de modelar con total precisión.

Mejoras del modelo:

Aumento de datos: Para definir mejor las distribuciones gaussianas de cada variable.

Selección de variables: Eliminar aquellas que causan solapamiento entre las Clases 0 y 1.

Validación Cruzada: Dado el tamaño reducido del dataset, para obtener una evaluación más robusta y menos dependiente del azar del split actual.

5. Conclusión

El modelo de Naive Bayes ha demostrado una eficacia sobresaliente para la clasificación química de vinos, logrando una identificación casi perfecta. La Clase 2 destaca como la más fácil de predecir debido a la singularidad de sus atributos, mientras que la Clase 1 presenta la mayor dificultad por su ligero solapamiento con la Clase 0. La principal limitación del estudio es el reducido tamaño del dataset, lo que hace recomendable aplicar validación cruzada en futuras iteraciones para garantizar que el rendimiento no dependa del azar del muestreo. En un escenario real, este modelo resulta altamente relevante por su equilibrio entre simplicidad y precisión, permitiendo una categorización automática fiable que optimiza los procesos de control de calidad con un coste computacional mínimo.