




Autores: Rubén Pérez González

Fecha: 25/02/2026

Asignatura: Sistemas de Aprendizaje Automático (IA)

Parte 1 — Exploración del dataset

1. ¿Cuántas clases tenemos y cuántos ejemplos de cada una?

Basándonos en la exploración de la variable objetivo, tenemos 2 clases:

Clase 1 (Benigno): 357 ejemplos.

Clase 0 (Maligno): 212 ejemplos.

Es un dataset ligeramente desbalanceado, con más casos benignos que malignos.

	mean radius	mean texture	mean perimeter	mean area	mean smoothness	mean compactness	mean concavity	mean concave points	mean symmetry	mean fractal dimension	...	worst texture	worst perimeter	worst area	worst smoothness
0	17.99	10.38	122.80	1001.0	0.11840	0.27760	0.3001	0.14710	0.2419	0.07871	...	17.33	184.60	2019.0	0.1622
1	20.57	17.77	132.90	1326.0	0.08474	0.07864	0.0869	0.07017	0.1812	0.05667	...	23.41	158.80	1956.0	0.1238
2	19.69	21.25	130.00	1203.0	0.10960	0.15990	0.1974	0.12790	0.2069	0.05999	...	25.53	152.50	1709.0	0.1444
3	11.42	20.38	77.58	386.1	0.14250	0.28390	0.2414	0.10520	0.2597	0.09744	...	26.50	98.87	567.7	0.2098
4	20.29	14.34	135.10	1297.0	0.10030	0.13280	0.1980	0.10430	0.1809	0.05883	...	16.67	152.20	1575.0	0.1374

5 rows × 31 columns

Distribución de las clases (0 = Maligno, 1 = Benigno):

label	
1	357
0	212

Name: count, dtype: int64

2. ¿Qué variables podrían ser más importantes para separar las clases?

Aunque en este ejercicio no hemos calculado las correlaciones exactas, en el contexto médico del cáncer de mama, las variables relacionadas con la geometría y la textura de los núcleos celulares suelen ser determinantes. Características como el radio medio, el área, la compactidad y la concavidad suelen tener valores significativamente diferentes entre tumores benignos y malignos, siendo por tanto importantes para la separación.

Parte 2 — SVM básico y visualización (Kernel Lineal)

1. ¿Qué tipo de frontera ves? Se observa una frontera de decisión lineal (una línea recta) que divide el plano en dos regiones (roja y azul).

2. ¿Crees que sería estable si añadimos un nuevo dato? Sí, la frontera parece relativamente estable. SVM busca el hiperplano que maximiza el margen entre las clases. Si se añade un dato nuevo que no sea extremadamente atípico cerca de la frontera, la línea no debería moverse drásticamente, especialmente con el parámetro de regularización por defecto $C=1.0$ que permite cierto margen suave.


3. ¿Qué pasaría si cambiamos C o γ ? Al estar usando un kernel lineal, el parámetro γ no tiene ningún efecto.

Si cambiamos C :


Aumentar C (p.ej., $C=100$): El modelo penalizaría mucho los errores de clasificación. Intentaría ajustar la línea para dejar la menor cantidad posible de puntos en el lado equivocado, lo que reduciría el margen y podría hacer la frontera menos estable ante ruido.

Disminuir C (p.ej., $C=0.01$): Se permitirían más errores en el entrenamiento. El margen se haría más ancho y la frontera sería más general, priorizando una separación amplia sobre clasificar perfectamente cada punto de entrenamiento.

La gráfica muestra una clara separación lineal en el espacio bidimensional estandarizado de las dos primeras variables. Aunque hay cierta superposición de clases en la zona central, el SVM lineal encuentra una división razonable.



Parte 3 — Probar distintos kernels



Kernel Linear: Muestra la frontera recta simple vista anteriormente. Parece subajustar ligeramente la complejidad de la zona central donde se mezclan los puntos.

Kernel RBF: Muestra una frontera curva, suave y cerrada que envuelve la clase mayoritaria en esa región. Parece adaptarse bien a la forma no lineal de los datos.

Kernel Poly: En este caso 2D, genera una curva parabólica que intenta separar las clases.

Kernel Sigmoid: Genera una frontera más compleja y en este caso particular parece menos intuitiva para la distribución de los datos.

Comentario sobre robustez: Visualmente, el kernel RBF parece el más robusto en este escenario 2D. Logra capturar la no linealidad necesaria para separar las clases superpuestas en el centro sin generar formas excesivamente erráticas o complejas, ofreciendo un buen equilibrio y una frontera de decisión suave.

¿Cuál kernel ajusta mejor los datos sin sobreajustar? Para estos datos en 2D, el kernel RBF parece ser el que mejor ajusta. El lineal es demasiado simple, y el polinómico o sigmoide a veces generan fronteras que no generalizan bien si no se ajustan sus parámetros cuidadosamente.

¿Cuál es más sensible al ruido? Los kernels no lineales, especialmente el RBF gamma es alto y el Polinómico si el grado es alto, son más sensibles al ruido. Pueden deformar la frontera de decisión para intentar clasificar correctamente puntos aislados o ruidosos, llevando al sobreajuste.

¿Cuál usaríais en un entorno real y por qué? En un entorno real, generalmente se empieza probando el kernel RBF. Es altamente versátil y eficaz para modelar relaciones complejas y no lineales en espacios de alta dimensión como el dataset completo de 30 características, y suele funcionar bien como primera opción robusta antes de probar kernels más específicos.

Parte 4 — Validación cruzada y GridSearch

```
Fitting 5 folds for each of 16 candidates, totalling 80 fits

--- Resultados GridSearchCV ---
Mejores hiperparámetros encontrados: {'C': 10, 'gamma': 0.01, 'kernel': 'rbf'}
Mejor score (CV): 0.9673
Score final en Test: 0.9883
```

1. ¿Qué hiperparámetros se eligieron y por qué? GridSearchCV seleccionó la combinación:

C: 10

gamma: 0.01

kernel: 'rbf'

Se eligieron estos parámetros porque fueron los que maximizaron la puntuación de accuracy promedio durante el proceso de validación cruzada de 5 pliegues obteniendo un score de CV de 0.9673. Es la combinación que, según la validación cruzada, ofrece el mejor equilibrio entre sesgo y varianza para este dataset.

2. ¿Cómo cambia la frontera si modificamos C o gamma? Las siguientes imágenes muestran cómo afecta la elección de hiperparámetros a la frontera RBF en 2D:




Imagen izquierda (C=0.1, gamma=1): Un gamma alto hace que el modelo sea muy sensible a puntos cercanos, resultando en una frontera muy compleja, irregular y fragmentada. Esto es un claro síntoma de sobreajuste. El C bajo permite margen, pero el efecto de gamma domina.

Imagen derecha ($C=100$, $\gamma=0.01$): Un γ bajo genera una frontera mucho más suave y generalizada. Aunque el C es alto, el γ bajo fuerza una solución más simple. Esto suele generalizar mejor.

3. ¿Qué pasa si probamos una rejilla más amplia? Si probamos una rejilla más amplia más valores o rangos más grandes para C y γ , aumentamos la probabilidad de encontrar una combinación de hiperparámetros que se acerque más al óptimo global, mejorando potencialmente el rendimiento del modelo. La desventaja es que el coste computacional aumenta significativamente, ya que el número de modelos a entrenar crece de forma multiplicativa.

4. ¿Cuál es la diferencia entre el score de CV y el score final en test?

Mejor score (CV): 0.9673: Es el promedio de exactitud obtenido en los conjuntos de validación durante el entrenamiento con los mejores parámetros. Sirve para seleccionar el modelo.

Score final en Test: 0.9883: Es la exactitud del modelo final (re-entrenado con todos los datos de train y los mejores parámetros) evaluado sobre el conjunto de test (datos totalmente nuevos).