


ENSAMBLE

DE

MODELOS



Autores: Rubén Pérez González

Fecha: 25/02/2026

Asignatura: Sistemas de Aprendizaje Automático (IA)

1. ¿Cuál es el modelo individual con mejor accuracy? El modelo individual que presenta el mejor rendimiento es el SVM, logrando un accuracy del 98.24%, seguido muy de cerca por la Regresión Logística con un 97.36%.

2. ¿Hay diferencias significativas entre ellos? Aunque no existen diferencias extremas, todos los modelos superan el 96% de precisión, lo que indica que las clases del dataset son relativamente fáciles de separar, el SVM logra una ventaja medible de casi dos puntos porcentuales por encima del modelo con menor rendimiento, el Random Forest 96.49%.

3. ¿Alguno muestra signos de posible overfitting? Sí, el Random Forest es el principal candidato a estar sufriendo sobreajuste (overfitting). Por la naturaleza de los árboles de decisión, este modelo suele memorizar los datos de entrenamiento (acercándose al 100% de accuracy en el conjunto de train), lo que provoca que generalice peor en datos nuevos, reflejándose en su puntuación más baja en el conjunto de test (96.49%).

```
RF: 0.9649122807017544  
SVM: 0.9824561403508771  
LR: 0.9736842105263158
```

Parte 3 - Implementar Stacking

1. ¿Mejora el stacking respecto al mejor modelo individual? En este caso concreto, el Stacking no ha mejorado el rendimiento. Ha obtenido un accuracy del 96.49%, igualando exactamente el resultado del modelo Random Forest por sí solo, y quedando por debajo del 98.24% logrado por el SVM individual.

2. Si la mejora es pequeña (ej. 0.5%), ¿compensa la complejidad añadida? Por norma general, no compensa. Implementar un modelo Stacking introduce una gran complejidad técnica: requiere más tiempo de entrenamiento, mayor consumo de memoria y dificulta enormemente la interpretabilidad del modelo (se convierte en una "caja negra"). Ante una mejora marginal, a nivel empresarial siempre es preferible optar por un modelo individual más sencillo, rápido y explicable.

3. ¿Qué papel está jugando la regresión logística como meta-modelo? La Regresión Logística actúa como el estimador final o "juez". Su función es recibir las predicciones generadas por los modelos base (Random Forest y SVM) y aprender a qué modelo debe darle más peso o confianza para tomar la decisión definitiva. En este experimento, el meta-modelo parece haber asimilado el sesgo del Random Forest, replicando su mismo resultado.

```
STACKING: 0.9649122807017544
```

Parte 4 - Análisis más profundo

1. ¿En qué casos está fallando el stacking? Según la matriz de confusión generada, el modelo comete únicamente 4 errores sobre el conjunto de prueba:

3 Falsos Negativos: El modelo predijo que el tumor era benigno, cuando en realidad era maligno. (En un contexto médico, este es el error de mayor gravedad).

1 Falso Positivo: El modelo predijo un tumor maligno cuando la etiqueta real era benigna.


2. ¿Crees que otro meta-modelo podría mejorar el resultado? ¿Cuál? Dado que el SVM ya tiene un rendimiento excelente, introducir un meta-modelo complejo puede generar ruido o sobreajuste. En su lugar, podría ser más efectivo utilizar un meta-modelo más restrictivo como un Ridge Classifier (para penalizar la dependencia excesiva de un solo modelo base) o simplemente optar por un Voting Classifier suave (Soft Voting), que promedie las probabilidades de ambos modelos sin necesidad de entrenar una capa adicional.

3. ¿Qué pasaría si eliminamos uno de los modelos base? Se perdería el pilar fundamental del Stacking: la diversidad. Si eliminamos el SVM, el meta-modelo únicamente recibiría como entrada las predicciones del Random Forest. Al no tener predicciones alternativas con las que comparar o combinar, el resultado del Stacking sería idéntico al del Random Forest de forma aislada.

4. ¿Por qué es obligatorio usar validación cruzada (cv) en el StackingClassifier?

Es imprescindible para evitar el filtrado de datos (Data Leakage). Si el meta-modelo se entrenara utilizando las predicciones que los modelos base hicieron sobre los mismos datos con los que ellos mismos se entrenaron, el meta-modelo aprendería a confiar ciegamente en el modelo más propenso al overfitting (aquel que simplemente ha memorizado los datos). El uso de cv garantiza que el meta-modelo aprenda combinando predicciones realizadas sobre datos "fuera de la muestra" (out-of-fold), simulando un escenario real.

--- INFORME DE CLASIFICACIÓN ---				
	precision	recall	f1-score	support
malignant	0.98	0.93	0.95	43
benign	0.96	0.99	0.97	71
accuracy			0.96	114
macro avg	0.97	0.96	0.96	114
weighted avg	0.97	0.96	0.96	114



Reflexión final

¿Cuándo usarías stacking en un proyecto real? ¿En qué situaciones no lo recomendarías? Utilizaría Stacking en competiciones de Machine Learning (como Kaggle) donde maximizar la métrica de éxito es el único objetivo, o en proyectos donde la precisión es absolutamente crítica, la latencia no es un problema y se cuenta con gran capacidad computacional (ej. detección de fraude a posteriori). Por el contrario, no lo recomendaría en sistemas que exijan predicciones en tiempo real (baja latencia), en despliegues con recursos limitados (dispositivos móviles, edge computing), ni en sectores altamente regulados (sanidad, banca) donde sea un requisito legal proporcionar alta explicabilidad sobre cómo el algoritmo ha llegado a una decisión concreta.