

FORECAST

El **forecast en series temporales** es **predecir valores futuros** de una variable usando su **historial en el tiempo** (por ejemplo, ventas diarias, consumo eléctrico por hora o tráfico web).

- Una **serie temporal** es una secuencia de datos **ordenados por fecha/hora**. El orden importa: no puedes mezclar el pasado con el futuro.
- El forecast puede ser:
 - **t+1**: predecir el siguiente paso (la próxima hora/día).
 - **t+h**: predecir varios pasos por delante (las próximas 24 horas, por ejemplo).
- Muchas series tienen patrones típicos:
 - **Tendencia** (sube o baja a largo plazo),
 - **Estacionalidad** (se repite cada cierto tiempo: diario, semanal...),
 - **Ruido** (variación impredecible).
- Para evaluar bien un modelo, el **test debe ser el futuro** (split temporal). Si entrenas con datos que “incluyen el futuro”, el resultado es engañoso.
- Siempre compara contra un **baseline**:
 - **Naive**: “mañana será igual que hoy”.
 - **Seasonal naive**: “hoy será igual que hace una semana”. Si tu modelo no mejora eso, probablemente no aporta.

“Comparar contra un **baseline**” significa que, antes de celebrar tu modelo (ARIMA, ML, etc.), lo comparas con una **predicción súper simple** que sirve como referencia mínima.

La idea es: **si tu modelo no mejora algo muy básico, entonces no está aportando valor**.

Ejemplos típicos de baseline en series temporales

1) Naive (persistencia)

- Predice que el próximo valor será igual al último observado:

$$\hat{y}_{t+1} = y_t$$

Ejemplo: si hoy vendiste 120, mañana predice 120.

2) Seasonal naïve

- Predice que será igual que el valor de hace “m” periodos (la estacionalidad):

$$\hat{y}_t = y_{t-m}$$

Ejemplo: si hay patrón semanal, “m=7 días”: predice que el lunes será como el lunes pasado.

Por qué es “recomendable”

Porque estos baselines, aunque simples, **son sorprendentemente fuertes**.

Si tu ARIMA/ML no los supera en MAE/RMSE, puede significar:

- no hay señal útil (la serie es casi ruido),
- el modelo está mal configurado,
- hay leakage/split mal hecho,
- o faltan variables (exógenas) importantes.

Mini-ejemplo rápido

Supón que tu baseline tiene **MAE = 10**.

- Tu ARIMA tiene **MAE = 12** → peor que baseline → **no sirve**
- Tu ARIMA tiene **MAE = 8** → mejor que baseline → **sí aporta**

En resumen: el baseline es tu “**rival mínimo**”. Si no lo ganas, no merece la pena usar un modelo más complejo.

- Los modelos clásicos como **ARIMA/SARIMA** funcionan bien cuando hay estructura (tendencia/estacionalidad) y sirven como punto de partida sólido.

En resumen: forecasting es **aprender los patrones del pasado** para **estimar el futuro**, midiendo el error con métricas como **MAE** o **RMSE** y validando siempre de forma **temporal**.

Casos de Uso:

1. **Demanda retail (ventas por tienda y producto)**
Prever unidades diarias/semanales para reposición y planificación de personal.




Ilustración 1 Retail (demanda diaria): tendencia + estacionalidad semanal + picos por promociones

2. **E-commerce: pedidos diarios y previsión de ingresos**
Forecast de pedidos para logística, empaquetado y capacidad de atención.
3. **Consumo eléctrico horario (utilities)**
Planificación de generación/compra y balanceo de red (m=24 y m=168 son comunes).




Ilustración 2 Energía (consumo horario): estacionalidad diaria/semanal

4. **Demanda de gas / calefacción**
Forecast por temperatura y estacionalidad para compras y operación.

5. **Producción industrial (volumen producido por hora/día)**

Ajuste de turnos y mantenimiento según previsión de producción.

6. **Tráfico web (usuarios activos/visitas por hora o día)**

Planificación de capacidad (autoscaling), campañas y estabilidad de sistemas.




Ilustración 3 Tráfico web (usuarios diarios): tendencia + semanal + campañas

7. **Uso de API / peticiones por minuto (SRE / DevOps)**

Dimensionamiento y alertas por picos previstos.

8. **Volumen de llamadas a call-center**

Forecast para scheduling de agentes y SLA.

9. **Demanda de transporte (ridesharing / taxis)**

Prever pickups por zona y franja horaria para pricing y posicionamiento de flota.

10. **Tráfico urbano (vehículos por tramo)**

Gestión de semáforos, predicción de congestión y planificación de obras.

11. **Ocupación hotelera**

Forecast de reservas para pricing dinámico, staffing y compras.

12. **Reservas en restaurantes**

Ajuste de personal y compras según previsión de covers por día/hora.

13. **Inventario y supply chain (demanda + lead time)**

Cálculo de reorder points y stock de seguridad con forecast.




Ilustración 4 Inventario: demanda diaria (para reaprovisionamiento)

14. **Rotación de stock perecedero (supermercados)**
Minimizar merma: forecast fino por día y promociones.
15. **Forecast de devoluciones (retail/e-commerce)**
Planificación de almacenes inversos y re-stock.
16. **Predicción de llegadas de paquetes (logística)**
Forecast de volumen diario para capacidad de sorting y rutas.
17. **Mantenimiento predictivo (sensores de vibración/temperatura)**
Forecast del sensor + detección de anomalías por residuales.




Ilustración 5 Sensores: drift + picos anómalos (útil para mantenimiento/anomalías)

18. **Calidad de fabricación (defectos por lote/turno)**
Forecast de tasa de defectos para intervención temprana.
19. **Epidemiología: casos diarios (salud pública)**
Prever demanda hospitalaria y recursos (camas, UCI), con estacionalidad.
20. **Farmacia: demanda de medicamentos**
Forecast para abastecimiento, evitando roturas en picos estacionales.
21. **Finanzas: volatilidad (riesgo) en vez de precio**
La volatilidad ($|returns|$) suele ser más predecible que el retorno medio.




Ilustración 6 Finanzas: returns (ruidosos) vs volatilidad proxy (más predecible)

22. **Banca: cash demand en cajeros (ATMs)**
Forecast de retiradas por día/semana para reposición de efectivo.
23. **Telecom: consumo de datos / tráfico de red**
Dimensionamiento de red y prevención de saturación.
24. **Energía renovable: producción eólica/solar**
Forecast de generación (muy dependiente de clima; SARIMAX con exógenas).
25. **Precios y demanda en marketplaces (pricing dinámico)**
Forecast de demanda y elasticidad para ajustar precios.
26. **RRHH: absentismo diario**
Forecast para planificación de turnos (estacionalidad semanal y eventos).
27. **Medios y contenido: reproducciones por hora/día**
Forecast de audiencia para programación y ads.
28. **Crédito: volumen de solicitudes por día**
Forecast de carga operativa en underwriting y sistemas.
29. **Gestión de residuos: volumen recogido por zona**
Forecast para optimización de rutas y recursos.
30. **Agricultura: series de humedad/temperatura de suelo**
Forecast para riego y detección de condiciones de estrés.


ARIMA

ARIMA es un modelo clásico para **predecir una serie temporal** usando **su propio pasado**. Combina tres componentes (p,d,q)


El algoritmo ARIMA (AutoRegressive Integrated Moving Average) es un método estadístico potente para el análisis y pronóstico de series temporales, combinando tres componentes: **Autorregresión (AR)** (relaciona el valor actual con valores pasados), **Integración (I)** (diferenciación para hacer la serie estacionaria) y **Media Móvil (MA)** (usa errores de predicción pasados). Se usa para predecir valores futuros en series con tendencias y patrones estacionales, como ventas o precios de acciones, transformando datos no estacionarios en estacionarios para modelarlos.

Su nombre resume lo que hace:

Qué significa ARIMA(p, d, q)



Objetivo:



1) AR (AutoRegresivo) = p

“Predigo el valor usando valores pasados(lags)”.

- Si **p = 2**, el modelo mira los **2 últimos valores**:

$$y_t \approx c + \phi_1 y_{t-1} + \phi_2 y_{t-2}$$

Intuición: si la serie tiene “memoria”, los últimos valores ayudan.

2) I (Integrado) = d

“Antes de modelar, convierto la serie en algo más estable (estacionaria)”.

Muchas series tienen tendencia y estacionalidad. ARIMA suele funcionar mejor si la serie es **estacionaria** (media y varianza más estables).

- Si **d = 1**, trabajamos con diferencias:

$$y'_t = y_t - y_{t-1}$$

Intuición: en vez de predecir el nivel, predices el **cambio**.

“**I (Integrado) = d**” significa cuántas veces haces **diferencias** a la serie para quitarle **tendencia** (y que sea más “estable”).

Ejemplo (muy simple)

Imagina esta serie (ventas por día):

- Día 1: 100
- Día 2: 105
- Día 3: 110
- Día 4: 115
- Día 5: 120

Esto tiene una **tendencia** clara (sube 5 cada día).

Si $d = 0$

No haces nada. Modelas la serie tal cual:

[100, 105, 110, 115, 120]

Pero ARIMA suele preferir una serie que no “se vaya hacia arriba” continuamente.

Si $d = 1$ (una diferencia)

Creas una nueva serie con los **cambios día a día**:

Cálculo:

- $105 - 100 = 5$
- $110 - 105 = 5$
- $115 - 110 = 5$
- $120 - 115 = 5$

Nueva serie (diferenciada):

[5, 5, 5, 5]

** Ahora es “estable”: ya no hay tendencia, es casi constante.

Eso es “Integrado $d=1$ ”: el modelo no predice directamente el nivel (100,105...), sino el **cambio**.

¿Y cómo vuelves al nivel original?

Si el modelo predice que mañana el cambio será +5, y hoy estás en 120:

- Predicción mañana = $120 + 5 = 125$

Si $d = 2$ (dos diferencias-otro ejemplo)

Solo si la primera diferencia aún tiene tendencia.

Ejemplo: si los incrementos fueran creciendo:

Serie original:

[100, 103, 109, 118, 130]

Diferencia 1:

[3, 6, 9, 12] (aún sube)

Diferencia 2:

[3, 3, 3] (ahora estable)

Regla práctica

- Si ves **tendencia**, prueba **$d=1$**
- $d=2$ es menos común (y puede “pasarse”)

3) MA (Media Móvil) = q

“Uso errores pasados para corregir mis predicciones”.

El componente MA dice: si en el pasado me equivoqué de cierta manera, lo uso para ajustar.

- Si **$q = 1$** :

$$y_t \approx \dots + \theta_1 \epsilon_{t-1}$$

Intuición: el modelo aprende patrones en los residuos (errores) y los compensa.

Imagina que intentas predecir ventas y tu modelo “base” siempre se queda corto cuando hay un pico.

Supón que hoy estás prediciendo con una regla simple y ayer pasó esto:

- **Ayer**: predije 100
- **Ayer real**: fue 110
- Entonces el **error de ayer** fue:

$$e_{t-1} = 110 - 100 = +10$$

Si tienes MA(1) (q = 1)

El modelo dice: “si ayer me quedé corto por +10, hoy ajusto un poco en esa dirección”.

Ejemplo de ajuste:

$$\hat{y}_t = \text{predicción base} + \theta_1 \cdot e_{t-1}$$

Si hoy tu predicción base es 102, y $\theta_1 = 0.6$:

$$\hat{y}_t = 102 + 0.6 \cdot 10 = 108$$

Nota: En un ARIMA real, el valor 0.6, **lo aprende el modelo automáticamente** al entrenar, ajustándolo para que las predicciones encajen lo mejor posible con los datos históricos.

¿Qué significa q = 2?

Usaría los **dos últimos errores**:

$$\hat{y}_t = \text{base} + \theta_1 e_{t-1} + \theta_2 e_{t-2}$$

Resumen en una frase

- **p (AR)** mira **valores pasados**
- **q (MA)** mira **errores pasados** (lo que fallaste antes) para corregir

Una explicación “de una frase”

ARIMA = “predigo el cambio de la serie (d) usando sus lags (p) y corrigiendo con errores pasados (q)”.

Ejemplo súper simple (con números)

Si tu serie es ventas diarias:

- tiene tendencia → pones **d=1**
- usa 1-2 lags → pruebas **p=1 o 2**
- añade corrección por errores → pruebas **q=1**

Entonces pruebas ARIMA(1,1,1), ARIMA(2,1,1), etc., y comparas contra baseline.