

Estadística descriptiva con R

1. Diferencia razonada entre datos cuantitativos discretos y continuos

Los datos cuantitativos son aquellos que se expresan mediante números y permiten realizar operaciones matemáticas. Dentro de ellos distinguimos dos tipos:

Datos cuantitativos discretos

Son aquellos que solo pueden tomar valores concretos, separados y normalmente enteros.

Esto ocurre porque representan conteos, es decir, cantidades que no pueden dividirse en partes más pequeñas de manera lógica.

Razón:

Cuando contamos elementos (personas, coches, libros...) no existen valores intermedios. Por ejemplo, no es posible tener 2,5 alumnos o 3,7 coches; solo tienen sentido números enteros. Además, entre dos valores posibles no existen infinitos valores intermedios: entre 2 y 3 no puede haber 2,4 o 2,8 en un conteo.

Ejemplos: Número de hijos por familia (0, 1, 2, 3...). Número de goles marcados en un partido. Número de estudiantes presentes en una clase. Número de llamadas recibidas en un día.

Datos cuantitativos continuos

Son variables que pueden tomar cualquier valor dentro de un intervalo, incluyendo fracciones y decimales.

Representan mediciones, y toda medición puede ser tan precisa como el instrumento lo permita.

Razón:

A diferencia de los conteos, las magnitudes físicas como la altura, el peso o el tiempo pueden dividirse infinitamente. Entre dos valores siempre hay otros posibles. Por ejemplo, entre 1,70 m y 1,71 m puede haber 1,705 m, 1,7042 m, etc. Esto hace que los valores posibles formen un continuo.

Ejemplos: Altura de una persona (1,73 m). Peso de un objeto (52,4 kg). Temperatura de un lugar (18,2 °C).

2. Datos cuantitativos

Fuente y variable elegida

He usado el fichero Number of Kids (numkids.csv) disponible en la página de datasets (Art of Stat). El fichero contiene, entre otras cosas, una columna con el

número de hijos (número entero: 0,1,2,...), que es una variable cuantitativa discreta (conteo). Fuente: Art of Stat — “Number of Kids”.

--- Discreto: Number of Kids ---

(1) Descargar y leer el CSV desde la web

```
url_numkids <- "https://img1.wsimg.com/blobby/go/bbca5dba-4947-4587-b40a-db346c01b1b3/downloads/numkids.csv?ver=1754347236238" numkids <- read.csv(url_numkids, stringsAsFactors = FALSE)
```

Mostrar primeras filas y nombre de columnas

```
head(numkids) names(numkids)
```

Supongamos que la columna con el número de hijos se llama 'num_kids' o similar.

Compruebo qué columnas hay y selecciono la que sea conteo:

Si no existe 'num_kids', busca una columna con "kids" en su nombre

```
colnames(numkids) kid_col <- grep("kid|child|num", tolower(names(numkids)), value = TRUE)[1]  
kid_col
```

Extraigo la variable discreta

```
kids <- numkids[[kid_col]]
```

Aseguro que sea numérica-entera

```
kids <- as.integer(kids)
```

Resumen y tamaño

```
length(kids) # número de observaciones summary(kids) # resumen básico
```

(2) Estadísticos descriptivos

```
table_kids <- table(kids) rel_freq <- prop.table(table_kids) cum_rel <- cumsum(rel_freq)
```

```
cat("Tabla de frecuencias (valor, freq, rel, cum.rel):\n") data.frame(value =  
as.integer(names(table_kids)), freq = as.vector(table_kids), rel_freq = round(as.vector(rel_freq),4),  
cum_rel = round(as.vector(cum_rel),4))
```

Media, mediana, moda, varianza, sd, rango

```
mean_k <- mean(kids, na.rm = TRUE) median_k <- median(kids, na.rm = TRUE) var_k <- var(kids,  
na.rm = TRUE) sd_k <- sd(kids, na.rm = TRUE) range_k <- range(kids, na.rm = TRUE)
```

Función moda para enteros

```
mode_k <- as.integer(names(sort(table_kids, decreasing = TRUE))[1])
```

```
list(mean = mean_k, median = median_k, mode = mode_k, variance = var_k, sd = sd_k, range =  
range_k)
```

(3) Visualizaciones

Barplot de frecuencias absolutas (discreto)

```
barplot(table_kids, main = "Número de hijos: frecuencias absolutas", xlab = "Número de hijos", ylab = "Frecuencia")
```

Gráfico de barras con frecuencias relativas (%)




```
barplot(100*rel_freq, main = "Número de hijos: frecuencias relativas (%)", xlab = "Número de hijos", ylab = "Porcentaje")
```

Histograma (aunque es discreto, se puede visualizar)

```
hist(kids, breaks = seq(min(kids)-0.5, max(kids)+0.5, by=1), main = "Histograma (discreto) del número de hijos", xlab = "Número de hijos")
```

(4) Tabla acumulada y percentiles

```
quantiles <- quantile(kids, probs = c(0.25, 0.5, 0.75), na.rm = TRUE) list(quantiles = quantiles)
```



Estos gráficos analizan una variable discreta (números enteros). Las principales conclusiones son:

La Moda es 2: La columna más alta en todos los gráficos indica que el tamaño de familia más frecuente es de 2 hijos. Es, por mucho, el valor más común.

Distribución Asimétrica (Sesgo a la derecha): La distribución no es simétrica. Hay una caída brusca hacia la izquierda (0 y 1 hijo son menos comunes que 2) y una "cola" larga hacia la derecha.

Frecuencia decreciente: Después de los 2 hijos, la frecuencia disminuye progresivamente. Tener 3 hijos es la segunda opción más común, pero tener 4 es mucho menos probable.

Eventos raros: Las familias con 5, 6 o 7 hijos representan un porcentaje muy pequeño de la muestra (frecuencia marginal muy baja).

Conclusión general: La muestra apunta a un modelo familiar estandarizado en torno a los 2 o 3 hijos, siendo las familias numerosas o las personas sin hijos (en esta muestra específica) minoritarias frente a la norma de 2.

2.ii) Datos cuantitativos continuos

a) Fuente y descripción

El conjunto de datos es Palmer Penguins, disponible públicamente.

Contiene medidas continuas en milímetros y gramos; se selecciona la variable:

bill_length_mm (longitud del pico en mm)

Es una variable cuantitativa continua, ya que puede tomar cualquier valor real dentro de un rango.

--- Continuo: Palmer Penguins ---

(1) Descargar y leer CSV desde el gist de GitHub

```
url_penguins <-
```

```
"https://gist.githubusercontent.com/slopp/ce3b90b9168f2f921784de84fa445651/raw/penguins.csv"
```

```
peng <- read.csv(url_penguins, stringsAsFactors = FALSE)
```

Ver primerísimas filas y columnas

```
head(peng) names(peng) nrow(peng) # número de observaciones
```

Selección de variable continua para el análisis (ej.: bill_length_mm)

```
x <- peng$bill_length_mm
```

(2) Limpieza: quitar NA

```
x_ok <- na.omit(x)
```

```
length(x_ok) # observaciones útiles (>=50 se cumple con este dataset)
```

(3) Estadísticos descriptivos

```
summary(x_ok) mean_x <- mean(x_ok) median_x <- median(x_ok) var_x <- var(x_ok) sd_x <- sd(x_ok)
range_x <- range(x_ok) quantiles_x <- quantile(x_ok, probs = c(0.25, 0.5, 0.75))
```

Skewness & kurtosis (instala paquete si es necesario)

```
if (!requireNamespace("e1071", quietly = TRUE)) install.packages("e1071") library(e1071) skew_x <-
e1071::skewness(x_ok) kurt_x <- e1071::kurtosis(x_ok)
```

```
list(mean = mean_x, median = median_x, variance = var_x, sd = sd_x, range = range_x, quantiles =
quantiles_x, skewness = skew_x, kurtosis = kurt_x)
```

(4) Visualizaciones


```
hist(x_ok, main = "Histograma: bill_length_mm", xlab = "Bill length (mm)") plot(density(x_ok), main =
"Densidad estimada: bill_length_mm", xlab = "Bill length (mm)") boxplot(x_ok, main = "Boxplot:
bill_length_mm", horizontal = TRUE, xlab = "Bill length (mm)")
```

(5) Normalidad (Shapiro-Wilk) - solo si $n < 5000$

```
shapiro_test <- shapiro.test(x_ok) shapiro_test
```

(6) QQ-plot

```
qqnorm(x_ok); qqline(x_ok)
```



Estos gráficos analizan una variable continua medida en milímetros. Las conclusiones estadísticas son más complejas aquí:

Distribución Bimodal (Clave): Tanto el histograma como el gráfico de densidad muestran claramente dos picos (jorobas).

Un grupo se concentra alrededor de los 38-40 mm.

Otro grupo se concentra alrededor de los 45-50 mm.

Interpretación: Esto sugiere fuertemente que la muestra no es homogénea. Probablemente contiene dos sub-poblaciones diferentes (por ejemplo, dos especies distintas de pingüinos o diferencias significativas entre machos y hembras).

No es una Distribución Normal:

La gráfica de densidad no tiene forma de campana perfecta (es bimodal).

El Normal Q-Q Plot confirma esto: los puntos se desvían de la línea recta diagonal, especialmente en los extremos y en el centro (formando una ligera "S"). Esto indica que los datos no siguen una distribución normal estándar.

Dispersión (Boxplot):

La mediana se sitúa alrededor de los 44-45 mm.

El rango intercuartílico (la caja gris) va aproximadamente de 39 mm a 49 mm.

El rango total de los datos va desde poco más de 30 mm hasta 60 mm. No se observan "outliers" (puntos aislados) extremos fuera de los bigotes del diagrama de caja.

Conclusión general: Al analizar la longitud del pico, no se debe tratar al grupo como uno solo. La bimodalidad indica que hay dos categorías mezcladas en los datos que deberían analizarse por separado para obtener medias y desviaciones típicas reales.