



Nombre: Rubén Pérez González

Asignatura: Sistemas de Big Data

Fecha: 12/12/2025

1. Análisis de Componentes Principales (PCA)

Qué es y para qué sirve: PCA es una técnica para simplificar datos. Imagina que tienes una tabla con muchísimas columnas (variables) numéricas. Lo que hace el PCA es "resumir" la información en unas pocas variables nuevas (llamadas componentes) que recogen lo más importante de los datos.

Se usa sobre todo cuando tienes datos numéricos (cuantitativos) y quieres ver patrones visualmente en un gráfico 2D, eliminando el ruido y la información repetida.

Ejemplo: Imagina las notas de un colegio con 10 asignaturas diferentes (Mates, Física, Dibujo, Historia, Lengua...).

- ¿Para qué usar PCA? En vez de mirar 10 notas por alumno, el PCA te sacaría dos "resúmenes" (componentes). Probablemente la PC1 sería "Habilidad Ciencias" y la PC2 "Habilidad Letras".
- ¿Qué aporta? Con un solo gráfico verías rápidamente los perfiles de los alumnos: quiénes son más de ciencias, quiénes de letras y quiénes son promedios, sin tener que comparar asignatura por asignatura.

2. Análisis de Correspondencias (CA)

Qué es y para qué sirve: El CA es el equivalente al PCA, pero para variables cualitativas (categorías, no números). Se usa para analizar tablas de frecuencias donde cruzas dos variables y ver la relación que tienen entre ellas.

Su objetivo es crear un "mapa" donde se pintan las categorías. Cuanto dos puntos están más cerca en el mapa más relacionados están.

Ejemplo: Imagina una encuesta sobre Género de cine favorito (Terror, Comedia, Acción) cruzado con el Rango de edad (Adolescente, Adulto, Jubilado).


- ¿Para qué usar CA? Para ver si la edad influye en el gusto.
- ¿Qué aporta? El gráfico te diría visualmente las preferencias. Si el punto "Terror" sale pegado a "Adolescente" y "Comedia" sale cerca de "Adulto", confirmas que hay una asociación clara entre esos perfiles. Ayuda a entender el comportamiento de grupos de un vistazo.

3. Ejercicio Práctico: Datos gabriel1971 (PCA)

El objetivo es Analizar las comodidades del hogar en distintas zonas de Jerusalén.

Primero se cargó la librería `bpca` y el dataset `gabriel1971` comprobándose mediante `summary` que los datos son numéricos. Después se ejecutó el PCA utilizando la función `prcomp` con el parámetro

scale=TRUE. Aunque las variables están en porcentajes, se optó por estandarizar para igualar la importancia de todas las variables y evitar que una comodidad muy frecuente domine artificialmente la varianza.



Los vectores representan las variables (Lavadora, TV, etc.). Todas las flechas apuntan mayoritariamente hacia la derecha, lo que indica que están correlacionadas positivamente entre sí: las zonas que tienen una comodidad suelen tener las otras.

Los individuos son las zonas geográficas. La primera componente principal explica la mayor parte de la varianza y actúa como un índice de Nivel de equipamiento.

Las zonas situadas a la derecha del gráfico tienen altos porcentajes de mayor nivel de vida. Las zonas a la izquierda carecen de estos bienes.


4. Ejercicio Práctico: Datos HairEyeColor (CA)

Su objetivo es analizar la relación entre color de pelo y color de ojos, y verificar si el sexo influye en esta relación.

Primero se cargó la librería `ca` y los datos. Después se desglosó el array de 3 dimensiones en tres tablas bidimensionales: Global (suma), Hombres y Mujeres. Y por último se realizaron tres análisis de correspondencias independientes.

Análisis Global

CA Global: Pelo vs Ojos




Se observa una clara estructura de asociación genética lógica.

El color de pelo Rubio está situado muy cerca de los ojos Blue Azules.

El pelo Negro está cerca de los ojos Marrones.

El centro del gráfico representa las combinaciones más comunes o medias, con menos diferenciación.

Comparativa Hombres vs Mujeres




Al comparar los mapas perceptuales de hombres y mujeres, observamos que la estructura geométrica es prácticamente idéntica. Las distancias entre las categorías de pelo y ojos se mantienen.

Esto nos indica que la asociación biológica entre la pigmentación del cabello y del iris es independiente del sexo del individuo. El patrón genético se mantiene estable en ambos grupos.

5. Ejercicio Opcional: Datos Propios

PCA sobre Dataset mtcars

Dataset interno de R. Se ha elegido este conjunto porque contiene exclusivamente variables cuantitativas (consumo, cilindros, potencia, peso, etc.), cumpliendo el requisito indispensable para un PCA.



PC1: Separa los coches según su potencia/peso vs. eficiencia. A la derecha vemos coches grandes y potentes (como Lincoln Continental, Cadillac Fleetwood) asociados a variables como wt (peso) y cyl (cilindros). A la izquierda, coches pequeños y eficientes (Toyota Corolla, Fiat 128) asociados a mpg (millas por galón).


PC2: Actúa como un discriminante de "Deportividad". En la parte superior del gráfico encontramos coches puramente deportivos y rápidos asociados a un mayor número de marchas. En la parte inferior se sitúan vehículos tipo sedán o de uso diario.

CA sobre Datos Simulados (Móviles vs Edad)

Origen: Datos generados manualmente mediante una matriz de contingencia 3x3.

Justificación del dataset: Se ha creado una tabla de frecuencias que cruza Grupos de Edad (Jóvenes, Adultos, Mayores) con Marca de Móvil (Apple, Samsung, Huawei). Al ser variables cualitativas nominales, el Análisis de Correspondencias es la técnica correcta.

CA Opcional: Edad vs Marca Móvil



Los jóvenes están más asociados con la marca Apple, indicando una fuerte preferencia de este segmento por dicha marca. Los mayores se posicionan cerca de Huawei, sugiriendo un perfil de usuario diferente. El grupo de Adultos se sitúa en una posición más central, cercana a Samsung. Estas distancias visuales nos permiten concluir que la edad es un factor discriminante en la elección de marca en este ejemplo.