

PROYECTO I: DISEÑO, IMPLEMENTACIÓN Y EVALUACIÓN DE MODELOS PREDICTIVOS



Predicción de Cobertura Forestal mediante Algoritmos de Machine Learning y Datos Cartográficos

Consultora: GeoData Insights

Cliente: Ministerio de Transición Ecológica (Servicio Forestal)

Autores: Rubén Pérez González Y Marcos Del Saz Nieto

Fecha: 18/03/2026

Asignatura: Sistemas de Aprendizaje Automático (IA)

ÍNDICE DE CONTENIDOS

1. FASE 1 — Definición del Problema [4]

1.1. Contexto y problema a resolver

1.2. Variable objetivo y tipo de problema

1.3. Impacto empresarial, riesgos y limitaciones

2. FASE 2 — Análisis Exploratorio de Datos (EDA) [6]

2.1. Análisis descriptivo y equilibrio de clases

2.2. Relación de variables topográficas y distribuciones

2.3. Análisis de correlación

3. FASE 3 — Preprocesamiento [8]

3.1. Tratamiento de nulos y muestreo de datos

3.2. Feature Engineering: Distancia real a fuentes de agua

3.3. Escalado de variables y Análisis de Multicolinealidad (VIF)

4. FASE 4 y 6 — Modelado, Evaluación y Análisis Crítico [10]

4.1. Comparativa de rendimiento global

4.2. Tiempos de entrenamiento y detección de Overfitting

4.3. Diagnóstico avanzado: Matriz de Confusión y Curvas ROC-AUC

5. FASE 5 — Optimización de Hiperparámetros [12]

5.1. Configuración de Validación Cruzada (K-fold)

5.2. Resultados del GridSearchCV en Random Forest

6. FASE 7 — Interpretabilidad y Reflexión [14]

6.1. Importancia de las variables (Feature Importance)

6.2. Discusión sobre precisión vs. interpretabilidad

6.3. Aplicabilidad real, limitaciones y propuestas de mejora

7. Bibliografía y Recursos Utilizados [16]

ÍNDICE DE ILUSTRACIONES

Ilustración 1: Distribución de Tipos de Cobertura Forestal y Elevación [6]

Ilustración 2: Matriz de Correlación de Variables Topográficas[7]

Ilustración 3: Dimensiones del dataset y Feature Engineering [8]

Ilustración 4: Análisis de Multicolinealidad (VIF) [9]

Ilustración 5: Tabla general de métricas por modelo [10]

Ilustración 6: Gráfico comparativo de rendimiento global en Test [10] **Ilustración**

7: Matriz de Confusión y Curvas ROC (OvR) de Random Forest [11] **Ilustración 8:**

Mejores parámetros de GridSearchCV[12] **Ilustración 9:**

Top 10 Variables más Determinantes (Feature Importance) [14]

FASE 1 — Definición del Problema

Para este proyecto, nos hemos puesto en la piel de una consultora de datos que trabaja para el Ministerio de Transición Ecológica. El objetivo principal de nuestro trabajo es hacer mucho más eficiente la manera en la que se gestionan los bosques y los recursos forestales hoy en día. Normalmente, para saber qué tipo de vegetación exacta hay en una zona concreta, el Ministerio tiene que organizar expediciones físicas que cuestan mucho dinero y tiempo, o bien tener a técnicos analizando a mano fotos de satélite, lo cual es súper lento y poco práctico si el área a estudiar es muy grande.

Problema a resolver: La idea que planteamos es desarrollar un modelo predictivo utilizando algoritmos de Machine Learning que sea capaz de clasificar qué tipo de cobertura forestal (la variable Cover Type) hay en distintas parcelas de tierra de 30x30 metros. Lo que hace que este enfoque sea bastante interesante y novedoso es que no vamos a usar ninguna imagen de satélite para ayudar al modelo. En su lugar, el algoritmo va a tener que aprender a clasificar los árboles usando únicamente datos del propio terreno, es decir, variables topográficas y geográficas como pueden ser la altitud a la que está la parcela, la inclinación de la pendiente, o a cuántos metros se encuentra la fuente de agua más cercana.

Variable Objetivo y tipo de problema: Nuestra variable a predecir, o variable objetivo, es Cover_Type. Esta columna del dataset contiene 7 clases diferentes de bosque (por ejemplo, Abetos, Pinos Lodgepole, Pinos Ponderosa, Álamos, entre otros). Como lo que queremos predecir son categorías concretas y discretas (es decir, clasificar si es el tipo de árbol A, B o C, y no adivinar un valor numérico continuo), estamos claramente ante un problema de Aprendizaje Supervisado, y más concretamente, de Clasificación Multiclase, ya que hay más de dos opciones posibles.

Impacto Empresarial y utilidad: A nivel de negocio o impacto real, conseguir que este modelo funcione bien sería un avance enorme para el Servicio Forestal. Básicamente, les permitiría crear mapas predictivos de los bosques súper precisos de forma automática y en


cuestión de segundos, simplemente introduciendo los datos del relieve de una zona nueva. Esto no solo significa ahorrar muchísimo dinero y recursos operativos, sino que además se convierte en una herramienta importantísima para cosas como prevenir incendios forestales (ya que dependiendo de qué tipo de bosque haya, el fuego se comporta de una forma u otra), proteger la biodiversidad de zonas vulnerables, o planificar de forma inteligente dónde se puede talar madera sin perjudicar al ecosistema.

Riesgos y Limitaciones: Ya desde el primer momento en que vimos el planteamiento del proyecto, nos dimos cuenta de que nos enfrentábamos a un problema bastante típico pero delicado: el desbalance de clases. Al final, los datos reflejan la naturaleza real del terreno, y en la naturaleza siempre hay especies de árboles que son súper comunes y cubren grandes áreas, mientras que otras son mucho más escasas. El gran riesgo técnico aquí es que, al haber tantos datos de unas pocas especies y tan pocos de otras, nuestro modelo se sesgue y tienda a predecir casi siempre las clases mayoritarias para ir a lo seguro. Tendremos que tener mucho cuidado con este sesgo y elegir bien las métricas a la hora de evaluar si los algoritmos realmente están aprendiendo.

FASE 2 — Análisis Exploratorio de Datos (EDA)

Antes de aplicar cualquier algoritmo, es obligatorio comprender la estructura y el comportamiento de nuestros datos para validar nuestras hipótesis iniciales.

Al analizar el equilibrio de la variable objetivo y la relación de los tipos de bosque con la topografía, extrajimos conclusiones reveladoras.



Interpretación visual:

El diagrama de cajas resulta muy revelador a nivel ecológico y estadístico. La variable "Elevación" demuestra ser un discriminador natural extraordinario. Podemos observar una estratificación casi perfecta:


Las especies de baja altitud (*Cottonwood/Willow*) tienen medianas en torno a los 2200 metros y presentan cajas muy compactas, indicando un hábitat muy específico.

Las especies de alta montaña alpina (*Krummholz*) se sitúan por encima de los 3300 metros.

Pero, por otro lado, nos dimos cuenta de un detalle súper importante al mirar la gráfica: hay un solapamiento brutal en las cajas (lo que técnicamente serían los rangos intercuartílicos) de altitud entre las dos especies que más abundan en todo el dataset, que son el Spruce/Fir y el Lodgepole Pine. Básicamente, la gráfica nos está diciendo que estos dos tipos de árboles crecen prácticamente a la misma altura en la montaña.

Si a este hecho de que se mezclen tanto le sumamos la enorme cantidad de valores atípicos u outliers que tienen los datos (que son todos esos puntitos que se ven dibujados por encima y por debajo de los "bigotes" en el diagrama de cajas), nos queda clarísimo que este va a ser el mayor dolor de cabeza de todo el proyecto. A nuestros algoritmos les va a costar muchísimo encontrar un patrón matemático y trazar una frontera clara para decidir si un árbol es de un tipo o del otro basándose solo en la elevación. Por culpa de esto, los modelos van a tener que aprender a combinar muy bien el resto de las variables que tenemos para poder "desempatar" y no equivocarse al clasificar estas dos especies.

Posteriormente, analizamos las relaciones lineales entre las variables continuas mediante una matriz de correlación.



Interpretación visual:

Posteriormente, generamos un mapa de calor para analizar la correlación lineal de Pearson entre las variables continuas. La matriz nos muestra que, en su mayoría, las variables topográficas aportan información independiente (baja colinealidad). Destacamos como relaciones lógicas fuertes:

La correlación negativa moderada (-0.78) entre `Hillshade_9am` y `Hillshade_3pm`, algo coherente con la física solar: las laderas muy iluminadas por la mañana suelen estar en sombra por la tarde.

La correlación positiva (0.61) entre las distancias horizontales y verticales al agua. Estas relaciones descartan el uso de modelos lineales simples y apuntan a la necesidad de algoritmos capaces de capturar dependencias jerárquicas complejas.

FASE 3 — Preprocesamiento

La calidad de un modelo predictivo está directamente ligada a la calidad de los datos que lo alimentan. En esta fase aplicamos las siguientes técnicas:

1. **Tratamiento de nulos y reducción del dataset:** Confirmamos la ausencia total de valores nulos (0 nulos). Dado el volumen masivo del dataset original (más de 581.000 filas), extrajimos una muestra estratificada del 10%. Esto garantiza la viabilidad computacional del proyecto manteniendo la proporción exacta de las especies forestales.
2. **Feature Engineering (Creación de nuevas variables):** Decidimos ir un paso más allá de los datos proporcionados y calcular la distancia euclídea real hacia fuentes de agua (la hipotenusa), combinando las distancias horizontales y verticales. Llamamos a esta nueva variable `Total_Distance_To_Hydrology`.

```
Cargando el dataset Coervertype...  
Feature Engineering completado: Creada variable 'Total_Distance_To_Hydrology'.  
Dimensiones de trabajo (Muestra 10%): 58101 filas y 55 variables.
```

3. **Escalado de Datos:** Aplicamos estandarización (StandardScaler) a las variables topográficas continuas. Esto es crucial para que variables medidas en grandes unidades (como metros de distancia) no opaquen a variables medidas en grados (como la pendiente).
4. **Análisis de Multicolinealidad (VIF):** Para comprobar si nuestra nueva variable generaba redundancia de información, calculamos el Factor de Inflación de la Varianza (VIF).

--- Análisis de Multicolinealidad (VIF) ---		
	Variable	VIF
10	Total_Distance_To_Hydrology	2203.475777
3	Horizontal_Distance_To_Hydrology	2072.736080
8	Hillshade_3pm	174.746519
6	Hillshade_9am	127.528689
7	Hillshade_Noon	44.958658
2	Slope	7.821200
4	Vertical_Distance_To_Hydrology	7.256888
1	Aspect	1.860230
0	Elevation	1.331310
5	Horizontal_Distance_To_Roadways	1.307168
9	Horizontal_Distance_To_Fire_Points	1.163643


Interpretación visual: Los resultados del VIF confirman una altísima multicolinealidad (valores superiores a 2000) entre nuestra nueva variable Total_Distance_To_Hydrology y la variable original Horizontal_Distance_To_Hydrology. En un entorno de regresión lineal estricto, deberíamos eliminar una de las dos. Sin embargo, dado que nuestro enfoque principal será utilizar modelos basados en árboles (robustos frente a la colinealidad), decidimos mantener ambas para permitir al algoritmo encontrar cortes no lineales en los datos.

FASE 4 y 6 — Modelado, Evaluación y Análisis Crítico

Para este reto, implementamos cinco algoritmos de distinta naturaleza: Árbol de Decisión, Random Forest, XGBoost, Gradient Boosting y Naive Bayes. Al ser un problema multiclase desbalanceado, priorizamos el F1-Score (Macro) y el cálculo de la curva ROC bajo la estrategia One-vs-Rest (OvR).

A continuación, se presentan los resultados obtenidos tras el entrenamiento y evaluación con el conjunto de prueba (Test).

	Modelo	Acc Train	Acc Test	Overfitting	Precision (Macro)	Recall (Macro)	F1-Score (Macro)	ROC AUC	Tiempo (s)
1	Random Forest	1.000000	0.880561	0.119439	0.879748	0.776412	0.815026	0.985046	2.736948
2	XGBoost	0.910951	0.847431	0.063520	0.830391	0.762844	0.789528	0.980261	3.540683
0	Árbol de Decisión	1.000000	0.831340	0.168660	0.737219	0.749892	0.743382	0.855606	0.773363
4	Gradient Boosting	0.761553	0.752173	0.009381	0.699943	0.595415	0.623703	0.948169	44.774573
3	Naive Bayes	0.099139	0.099475	-0.000336	0.228038	0.443969	0.125370	0.802990	0.110372




Comparación de rendimiento y análisis crítico:

- Modelos ganadores:** Random Forest y XGBoost demuestran un rendimiento superior absoluto. Random Forest lidera con un Accuracy del 88% y un notable F1-Score Macro del 81.5%, demostrando gran capacidad para aislar patrones no lineales complejos.
- El fracaso de Naive Bayes:** El algoritmo Naive Bayes obtiene un rendimiento catastrófico (apenas un 10% de acierto). Esto se justifica analíticamente: Naive Bayes

asume independencia total entre las variables, algo que, como demostramos en nuestro análisis VIF y de correlación, no se cumple en la topografía natural.

3. **Tiempos de entrenamiento:** Gradient Boosting resultó ser ineficiente para este problema multiclase, tardando casi 45 segundos para ofrecer un rendimiento mediocre, mientras que XGBoost y Random Forest convergieron en menos de 4 segundos.
4. **Detección de Overfitting:** Se detectó un sobreajuste evidente en el Árbol de Decisión simple (100% en Train vs 83% en Test). Random Forest también presenta indicios de memorización (diferencia del 11.9% entre Train y Test), algo que abordaremos en la fase de optimización.

Para profundizar en los aciertos y errores de nuestro mejor modelo (Random Forest), generamos su Matriz de Confusión y sus Curvas ROC.



Interpretación visual: La matriz de confusión revela que el modelo clasifica con brillantez casi todas las clases. La principal fuente de error (los números fuera de la diagonal central) se produce al intentar distinguir entre *Spruce/Fir* y *Lodgepole Pine*. Como vimos en el EDA, estas dos especies comparten la misma franja de altitud, lo que induce al modelo a la confusión. Por otro lado, las curvas ROC-AUC validan la robustez del modelo. El área bajo la curva es casi perfecta (entre 0.96 y 1.00 para todas las especies), indicando una capacidad de discriminación excepcional.

FASE 5 — Optimización de Hiperparámetros

Habiendo identificado indicios de *overfitting* en el Random Forest base (generado por el crecimiento descontrolado de los árboles hasta su pureza total), procedimos a la fase de optimización o "tunning" para dotar al modelo de una mayor robustez y capacidad de generalización empírica.

Configuración de Validación Cruzada (K-fold): Para garantizar que nuestros resultados de optimización no fuesen fruto de la casualidad por una división favorable de los datos, implementamos validación cruzada estratificada (StratifiedKFold con K=3). Esto asegura que el modelo se entrene y se valide internamente en 3 subconjuntos diferentes de datos, manteniendo en todo momento la proporción real de cada tipo de cobertura forestal en cada pliegue.

Resultados del GridSearchCV y análisis de hiperparámetros: Definimos una malla de búsqueda (GridSearchCV) centrada en restringir la complejidad estructural de los árboles para prevenir que memoricen el ruido:

- `n_estimators` (número de árboles en el bosque).
- `max_depth` (profundidad máxima de las ramas).
- `min_samples_split` (cantidad mínima de observaciones para permitir una división).

```
Ejecutando GridSearchCV...  
Mejores parámetros: {'max_depth': 30, 'min_samples_split': 2, 'n_estimators': 150}  
F1-Macro Optimizado: 0.8111
```

Después de dejar ejecutando el algoritmo para que probase absolutamente todas las combinaciones que le pasamos en la malla (lo cual le llevó un buen rato de procesamiento), los resultados del GridSearchCV nos confirmaron cuál era la configuración ideal para conseguir que el modelo fuera lo más estable posible.


Básicamente, la conclusión fue que lo mejor es ponerle un límite a la profundidad máxima de los árboles, dejándola en 30 (`max_depth: 30`). Además, nos indicó que un nodo necesita tener como mínimo 2 muestras dentro para que el algoritmo decida seguir dividiéndolo (`min_samples_split: 2`), y que lo más óptimo para este dataset es montar un "bosque" compuesto por 150 árboles tomando decisiones al mismo tiempo (`n_estimators: 150`).

Lo verdaderamente interesante de haberle impuesto estas restricciones al modelo, y sobre todo el hecho de haberle cortado la profundidad para que los árboles no crezcan infinitamente, es que tiene un impacto súper directo en el problema que teníamos de sobreajuste. Lo que conseguimos con esto es obligar a los árboles a que dejen de aprenderse los datos de entrenamiento de memoria. Dicho de otra forma, evitamos que se obsesionen con detalles, excepciones o "ruido" insignificante del dataset, obligándoles a captar los patrones generales para que funcionen bien de verdad cuando les pasemos datos topográficos que no han visto nunca.

Comparación entre modelo base y modelo optimizado: El modelo Random Forest *base* (por defecto) obtuvo un F1-Score Macro de **0.8150**, pero arrastraba un sobreajuste evidente al memorizar el 100% de los datos de entrenamiento. Tras la optimización, nuestro modelo consolidó un F1-Score Macro de **0.8111**. Aunque numéricamente supone un levísimo descenso de 0.0039 puntos en el test, a nivel de consultoría y negocio **el modelo optimizado es infinitamente superior**. Hemos sacrificado una precisión irreal basada en la memorización por una verdadera capacidad de generalización empírica, obteniendo un sistema estable y listo para su puesta en producción sin riesgo de fallos ante datos topográficos nunca antes vistos.

FASE 7 — Interpretabilidad y Reflexión

En GeoData Insights sabemos que un modelo no debe ser una "caja negra". Los biólogos e ingenieros forestales necesitan comprender qué motiva las decisiones de la IA. Para ello, extrajimos la importancia de las variables (Feature Importance) del modelo optimizado.



Interpretación de variables: La gráfica confirma rotundamente lo intuido durante el análisis exploratorio: la **Elevación** es el factor más crítico para predecir el tipo de ecosistema, liderando el gráfico con gran margen. Destaca también que la variable que creamos mediante Feature Engineering (Total_Distance_To_Hydrology) se posiciona en el Top 4 de importancia global, justificando plenamente el esfuerzo de preprocesamiento invertido.

Precisión vs. Interpretabilidad: Durante este proyecto, nos enfrentamos al clásico dilema del Data Science: interpretabilidad versus precisión. El modelo de *Árbol de Decisión* original era 100% interpretable visualmente; podíamos imprimirlo en papel y seguir sus reglas "Si/No" desde la raíz hasta las hojas. Sin embargo, su precisión caía en picado ante datos nuevos. Hemos optado por sacrificar esa transparencia lineal explícita en favor de un algoritmo de *Ensemble* (Random Forest), ganando una enorme robustez predictiva. Para compensar la pérdida de interpretabilidad directa, nos apoyamos en técnicas de interpretabilidad global a posteriori (como la gráfica de importancia de variables) para justificar y auditar las decisiones del modelo.

Discusión sobre la aplicabilidad real y limitaciones:

- **Aplicabilidad:** La solución desarrollada tiene un valor operativo inmediato. El Servicio Forestal puede cargar cartografía digital topográfica (DEMs, Modelos de Elevación Digital) de zonas vírgenes o quemadas, y el algoritmo generará un mapa de cobertura

forestal estimado en segundos, sirviendo como una herramienta de primer nivel para la planificación territorial.

- **Limitaciones:** La principal debilidad de nuestro modelo es que le cuesta mucho predecir las clases minoritarias (como Cottonwood/Willow o Aspen). Como ha visto muy pocos ejemplos de estos árboles durante el entrenamiento, cuando las características del terreno le generan dudas, el algoritmo prefiere ir a lo seguro. Termina clasificando esa zona como uno de los bosques mayoritarios simplemente para equivocarse lo menos posible a nivel global.

Propuestas de mejora futura: Como próximos pasos, recomendamos al Servicio Forestal dos vías de actuación:

1. Implementar técnicas de sobremuestreo sintético (como SMOTE) durante el entrenamiento para equilibrar las clases minoritarias.
2. Incorporar datos climáticos históricos (temperatura y precipitación promedio de cada parcela) al conjunto de características, ya que la botánica depende críticamente de dichos factores, lo que muy probablemente resolvería la confusión de altitud entre los pinos *Lodgepole* y los abetos.

8. Bibliografía y Recursos Utilizados

1. **Scikit-learn developers (2024).** *Scikit-learn: Machine Learning in Python*. Documentación oficial. Disponible en: <https://scikit-learn.org/>
2. **McKinney, W. (2010).** *Data Structures for Statistical Computing in Python* (Pandas). Proceedings of the 9th Python in Science Conference.
3. **Waskom, M. (2021).** *Seaborn: statistical data visualization*. Journal of Open Source Software.
4. **Chen, T., & Guestrin, C. (2016).** *XGBoost: A Scalable Tree Boosting System*. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining.
5. Material teórico, apuntes y metodologías trabajadas durante las sesiones académicas del curso de Data Science.