

Práctica: Ofuscación de datos con `re` (Python)

Objetivo

Vas a construir un **ofuscador de datos personales** que, a partir de un fichero de texto con ~2000 líneas (una oración por línea), genere otro fichero **idéntico** salvo porque ciertos datos sensibles se sustituyen por **etiquetas**.

Tu solución debe usar **solo la librería estándar `re`** (expresiones regulares) para **buscar y reemplazar**.

Archivos de trabajo

Se te proporcionan dos ficheros:

- **Entrada:** `texto_original_2000_lineas_casos_raros_v2.txt`
- **Salida esperada:** `texto_ofuscado_2000_lineas_casos_raros_v2.txt`

Tu programa debe transformar la **entrada** y producir una salida que coincida con la **salida esperada**.

Qué tienes que detectar y sustituir (reglas)

Debes sustituir **solo los valores** (no el texto alrededor) por las siguientes etiquetas:

- Nombre y apellidos → `<nombre_apellidos>`
- Cuenta → `<cuenta>`
- Email → `<mail>`
- Teléfono → `<telefono>`
- Dirección (tipo calle/avenida con número, etc.) → `<direccion>`
- Localidad → `<localidad>`

Regla de oro

- ✓ La línea resultante debe mantener **exactamente** la misma **redacción y puntuación** que la original.
 - ✓ Solo cambias los datos por su etiqueta.
 - ✗ No añadas flechas, paréntesis, comillas, ni texto extra.
 - ✓ Si un dato aparece **varias veces** en una línea, debes ofuscarlo **todas las veces**.
-

Formatos que debes soportar

1) <nombre_apellidos>

Aparece tras el literal `El cliente` y puede contener:

- 2–4 “tokens” (nombre + apellidos), con variaciones como:
 - Partículas: `de`, `del`
 - Apellidos con guion: `Santos-Tejada`
 - Tildes y caracteres españoles

Ejemplo:

- `El cliente Andrés Linares de Crespo ...` → `El cliente <nombre_apellidos> ...`

2) <mail>

Correos con dominio `example.*` y variaciones realistas:

- TLDs permitidos: `example.com`, `example.es`, `example.org`
- Puede haber **subdominio**: `dept.example.com` (y equivalentes en `.es/.org`)
- El *local-part* puede incluir:
 - `.`, `_`, `-`
 - `+alias` (por ejemplo `+facturacion`)
 - Mezcla de mayúsculas/minúsculas

Ejemplos válidos:

- `marta.prieto@example.es`
- `Lucia_Delgado+ventas@dept.example.org`

3) <telefono> (con prefijo internacional)

Teléfonos con prefijo usando `+` o `00`, con separadores variados y, a veces, extensión:

Variantes típicas:

- `+34 612345678`
- `(+49) 1512345678`
- `00 34 612 345 678`
- `00351-912345678`
- Con extensión:
 - `+34 912345678 ext. 204`
 - `+34 912345678 x204`

 **Debes sustituir el teléfono completo**, incluyendo la extensión si aparece.

4) <cuenta> (4 formatos distintos)

Cuentas con variaciones y, a veces, espacios alrededor de separadores:

Formatos válidos (ejemplos):

1. AB-0987654321 (2 letras + - + 10–12 dígitos)
2. AB/1234567890 (2 letras + / + 10 dígitos)
3. QWE-12345678-ZX (3 letras + - + 8 dígitos + - + 2 letras)
4. AB12-123456789012 (2 letras + 2 dígitos + - + 12 dígitos)

Variaciones a soportar:

- Espacios: AB - 0987654321, AB / 1234567890

5) <direccion> y <localidad>

Aparecen en fragmentos tipo:

- domicilio <direccion> de <localidad>
- con domicilio en <direccion> de <localidad>
- Y pueden incluir notas como (portal 2) que **NO** se etiqueta.

Dirección:

- Empieza con calle, avenida o abreviaturas: c/, avd., avda., Av., Avda
- Incluye número, a veces con sufijo: 12B
- Puede incluir piso: , 3ºB

Localidad:

- Puede ser de **una o varias palabras**:
 - San Esteban, Ribera Alta, San Martín del Río

Ejemplo:

- domicilio c/ Olmo 12B, 3ºA de San Esteban
→ domicilio <direccion> de <localidad>

Casos trampa (falsos positivos) que debes evitar

El texto incluye “señuelos” que **parecen** datos, pero **no deberían** ofuscarse si tu regex es estricta:

- “Casi-cuentas”:
 - AB-123456789 (9 dígitos)
 - AB-1234567890123 (13 dígitos)
 - AB_1234567890 (separador incorrecto)
 - ref. AB-ABC (no numérico)

✓ Parte de la práctica es lograr buen equilibrio entre **captura** y **evitar falsos positivos**.

Tarea a entregar

1. Un script `ofuscar.py` (o notebook) que:
 - Lea el fichero original.
 - Aplique sustituciones con `re` para todas las etiquetas anteriores.
 - Escriba un fichero de salida, por ejemplo: `mi_salida.txt`
 2. Una comprobación de calidad:
 - Comparar `mi_salida.txt` con `texto_ofuscado_2000_lineas_casos_raros_v2.txt` (por ejemplo con `diff`, o comparando líneas en Python).
 - Mostrar:
 - N° de líneas iguales / distintas
 - (Opcional) primeras 5 diferencias encontradas
-

Criterios de evaluación

- **Correctitud**: tu salida coincide con la salida esperada (máxima puntuación).
 - **Robustez**: reemplazas todas las apariciones y soportas variaciones.
 - **Precisión**: minimizas falsos positivos (no etiquetas cosas que no son).
 - **Código**: claridad, orden y mantenibilidad (regex legibles y comentadas).
-

Ejemplo ilustrativo (no necesariamente del dataset)

Entrada:

El cliente Marta Santos Vega con correo
marta.santos+ventas@dept.example.com y teléfono 00 34 912 345 678 ext.
204, con domicilio en avda. Sierra 12B de San Esteban, ha
solicitado...

Salida:

El cliente <nombre_apellidos> con correo <mail> y teléfono <telefono>, con domicilio en <direccion> de <localidad>, ha solicitado...
