



Autor: Rubén Pérez González

Fecha: 26/11/2025


Asignatura: Sistemas de Aprendizaje Automático (IA)


1. Introducción y Análisis Exploratorio (EDA)

El objetivo de este análisis es evaluar la calidad de los datos del dataset empresarial, identificando valores atípicos (outliers) y errores de consistencia para proponer una estrategia de limpieza adecuada.

1.1. Análisis Visual Detallado (EDA)

Para comprender en profundidad el comportamiento de los datos, hemos desglosado el análisis visual en dos dimensiones: la forma de la distribución (Histograma) y la detección de valores atípicos (Boxplot).





Ingresos

Histograma: La distribución principal de los datos se concentra en un rango muy definido entre las 20.000 y 30.000 unidades monetarias. Sin embargo, se observa una barra aislada y diminuta en el extremo derecho del gráfico (eje X $\approx$ 150.000), totalmente separada del resto de la población. Esto indica una discontinuidad severa en los datos.

Boxplot: El diagrama de caja confirma que la dispersión central (el rango intercuartílico) es pequeña y estable. No obstante, aparece un único punto outlier extremadamente alejado del "bigote" superior. Al ser un caso único y tan distante, sugiere fuertemente un evento excepcional o un error de entrada manual.

Costes

Histograma: A diferencia de los ingresos, la distribución de costes muestra una asimetría positiva (cola hacia la derecha) más pronunciada y continua. Aunque el grueso de los datos está en torno a los 10.000, existen registros frecuentes que se extienden hacia valores más altos (20k, 30k, 40k...).

Boxplot: Se observan múltiples puntos atípicos por encima del límite superior del bigote. No es un solo punto aislado, sino una "nube" de valores que llega hasta los 60.000. Esto indica que los costes elevados no son un error puntual, sino una característica del negocio (posiblemente proyectos grandes) que debe gestionarse con técnicas de capping.

Satisfacción

Histograma: La mayoría de las calificaciones se agrupan lógicamente entre 3 y 5. Sin embargo, el histograma revela pequeñas barras en zonas imposibles: valores cercanos a 0 y valores superiores a 5. Al tratarse de una escala cerrada (1-5), esto alerta inmediatamente sobre problemas de calidad.

Boxplot: Identifica con precisión los valores culpables. Vemos outliers situados en 0.1 y en 6.0. Al estar claramente fuera de la escala permitida, estos puntos no deben interpretarse como opiniones extremas, sino como errores de dato que requieren corrección (imputación).

Empleados

Histograma: Muestra una distribución extremadamente sesgada a la derecha. La inmensa mayoría de los departamentos tienen menos de 50 empleados (la barra más alta). Visualmente, el resto del eje X está vacío hasta aparecer una pequeña marca en el valor 300.

Boxplot: La "caja" está muy comprimida en la parte inferior, lo que indica que casi todos los departamentos tienen un tamaño similar y pequeño. Sin embargo, destaca un outlier solitario en 300. Este valor es tan desproporcionado respecto a la mediana que, de no tratarse, distorsionaría gravemente el cálculo del promedio de plantilla de la empresa.

2. Resultados de los Métodos de Detección

Método 1: Z-Score (Detección Paramétrica)

El Z-Score busca valores que se alejen más de 3 desviaciones estándar de la media.

```
--- Detección por Z-Score ---
Outliers detectados en ingresos (Z-Score > 3): 2
Outliers detectados en costes (Z-Score > 3): 2
Outliers detectados en satisfaccion (Z-Score > 3): 2
Outliers detectados en empleados (Z-Score > 3): 1
```

	ingresos	costes	satisfaccion	empleados	departamento	region	canal
400	100000	12517	3.167049	18	Operaciones	Islas	partners
401	150000	12974	3.931346	27	IT	Norte	partners

Análisis de Resultados:

Este método ha detectado un número bajo de outliers: 1 en ingresos, 9 en costes, 2 en satisfacción y 1 en empleados.

Limitación observada: Al ser un método sensible a valores extremos (que "estiran" la desviación estándar), el Z-Score es muy conservador. Es probable que esté pasando por alto anomalías moderadas, detectando solo los casos más exagerados.

Método 2: IQR (Rango Intercuartílico)

Este método define los outliers basándose en la mediana y los cuartiles (Q1 y Q3), siendo mucho más robusto que el Z-Score.

```

--- Detección por IQR ---
Outliers detectados en ingresos (IQR): 3
  Límites ingresos: < 14239.00 | > 35823.00
Outliers detectados en costes (IQR): 2
  Límites costes: < 5177.50 | > 17693.50
Outliers detectados en satisfaccion (IQR): 2
  Límites satisfaccion: < 2.14 | > 5.56
Outliers detectados en empleados (IQR): 1
  Límites empleados: < -16.00 | > 72.00

```

	ingresos	costes	satisfaccion	empleados	departamento	region	canal	
	408	24937	10548	4.378294	300	Marketing	Este	online

Análisis de Resultados:

Como se observa, el IQR es mucho más sensible: detecta 22 outliers en costes (frente a los 9 del Z-Score) y 36 en empleados (frente a 1).

En la variable empleados, esta diferencia es crucial: el Z-Score solo vio el caso extremo (300 empleados), pero el IQR detectó que hay un grupo considerable de departamentos que se salen de la norma habitual, ofreciendo una visión más realista de la variabilidad de los datos.

Método 3: MAD y Método Extra (Isolation Forest)

Finalmente, aplicamos el MAD (el método estadístico más robusto) y un algoritmo de Machine Learning (Isolation Forest) para detectar anomalías complejas.

```

--- Detección por MAD (Z-Score Modificado) ---
Outliers detectados en ingresos (MAD): 3
Outliers detectados en costes (MAD): 2
Outliers detectados en satisfaccion (MAD): 1
Outliers detectados en empleados (MAD): 1

--- Método Extra: Isolation Forest ---
Total de filas detectadas como anomalías por Isolation Forest: 21

```

Análisis de Resultados:

MAD: Muestra resultados muy similares al IQR en variables críticas como costes (22 detectados), confirmando la consistencia de la detección robusta. Destaca que en satisfacción detecta 15 casos; esto se debe a que la desviación mediana es muy pequeña, por lo que cualquier valor ligeramente alejado del centro se marca como outlier (demasiada sensibilidad en este caso específico).

Isolation Forest: Ha detectado un total de 21 filas anómalas analizando todas las variables a la vez. Esto es útil porque no solo mira si un valor es alto, sino si la combinación de valores es extraña (ej. pocos empleados, pero costes altísimos).

3. Comparación entre Métodos

Comparación de número de outliers detectados por método:

	Variable	Z-Score (N)	IQR (N)	MAD (N)
0	ingresos	2	3	3
1	costes	2	2	2
2	satisfaccion	2	2	1
3	empleados	1	1	1

3.1. Análisis de las Discrepancias

Al analizar la tabla, observamos comportamientos muy distintos entre los algoritmos:

El "Enmascaramiento" del Z-Score (Costes y Empleados):

El método Z-Score detecta muchos menos outliers que el IQR (9 vs 22 en Costes, 1 vs 36 en Empleados).

¿Por qué pasa esto? El Z-Score depende de la desviación estándar. Al existir valores extremos muy grandes (como el departamento de 300 empleados), la desviación estándar aumenta drásticamente, haciendo que el "umbral de corte" sea muy alto. Esto provoca que el algoritmo sea demasiado "permisivo" y no detecte anomalías moderadas.

La sensibilidad del IQR en distribuciones sesgadas (Empleados):

El dato más llamativo es la variable Empleados: El IQR detecta 36 outliers, mientras que Z-Score y MAD solo detectan 1.

Esto sugiere que la variable no sigue una distribución normal y tiene una "cola larga" (muchos departamentos de tamaño medio-alto). El IQR es capaz de identificar todo ese grupo de departamentos inusualmente grandes, mientras que los otros métodos solo ven el caso extremo único (el de 300 empleados).

La sobre-sensibilidad del MAD (Satisfacción):

En la variable Satisfacción, el método MAD detecta 15 outliers, frente a los 1 o 2 de los otros métodos.

Al ser una escala pequeña (1-5), la variabilidad es baja. El MAD es tan estricto analizando la mediana que está marcando como "anomalía" valores que probablemente son variaciones normales de la opinión de los usuarios (Falsos Positivos).

3.2. Selección del Método Ganador

Descartamos el Z-Score: Es demasiado conservador. Si lo usáramos, dejaríamos "sucios" los datos de Costes, ignorando 13 registros problemáticos que el IQR sí vio.

Descartamos el MAD para variables acotadas: En Satisfacción es demasiado agresivo y eliminaría datos válidos.

Elegimos el método IQR: Es el más equilibrado para este dataset. Detecta eficazmente los problemas estructurales en Costes e Ingresos y nos alerta sobre el grupo de departamentos grandes en Empleados, sin depender de que la distribución sea perfectamente normal.

4. Tratamiento de Datos y Resultados

Ejecutamos las reglas de limpieza definidas para corregir los errores sin perder información valiosa.

```
--- Tratamiento de Datos ---  
Eliminando 0 registros con ingresos negativos.  
Imputando 2 valores de satisfacción fuera de rango con la mediana (3.84).  
Topeando 21 valores de costes al percentil 95 (14633.00).
```

Estadísticas después de la limpieza:

	ingresos	costes	satisfaccion	empleados
count	409.000000	409.000000	409.000000	409.000000
mean	25400.039120	11491.078240	3.854808	28.515892
std	7855.275835	1922.655371	0.497293	18.678927
min	5000.000000	8002.000000	3.002063	0.000000
25%	22333.000000	9871.000000	3.429704	17.000000
50%	24816.000000	11502.000000	3.837568	27.000000
75%	27729.000000	13000.000000	4.279258	39.000000
max	150000.000000	14633.000000	4.795058	300.000000

Ingresos: Verificación de integridad. No se encontraron valores negativos (0 eliminados).


Satisfacción: Se detectaron 2 valores erróneos. En lugar de borrar las filas, se imputaron con la mediana (3.83) para conservar al cliente.

Costes: Se detectaron 21 valores extremos. Se aplicó Capping al percentil 95, limitando el valor máximo a 14.633 para evitar distorsiones en la media.

Validación: La tabla estadística final confirma el éxito: la variable satisfaccion está ahora estrictamente entre 1 y 5, y la desviación estándar de costes se ha reducido, indicando unos datos más estables y fiables.

5. Visualización Final: Impacto del Tratamiento

Para validar la efectividad de nuestra estrategia de limpieza, generamos una comparativa visual de la variable más crítica (Costes) antes y después del tratamiento.



Análisis Comparativo

Costes Originales (Gráfico Rojo - Izquierda):

Se observa una distribución extremadamente dispersa. La "caja" principal (donde reside el 50% de los datos) aparece muy comprimida debido a la presencia de una larga cola de outliers (puntos negros) que se extienden verticalmente hasta valores cercanos a 60.000.

Problema: Esta dispersión extrema inutiliza la media como métrica fiable, ya que unos pocos valores altos la arrastran hacia arriba.

Costes Tratados (Gráfico Verde - Derecha):

Solución: Tras aplicar el Capping al percentil 95, observamos que los outliers superiores han desaparecido por completo.

Resultado: La distribución se ha compactado. El valor máximo ahora está acotado estrictamente en 14.633. Esto significa que hemos eliminado el "ruido" estadístico sin perder la información de negocio (los costes altos siguen siendo altos, pero dentro de un límite controlable).