







Clustering IV



Clustering Jerarquico

El **clustering jerárquico** es una familia de métodos de clustering no supervisado que construye una jerarquía de grupos (un “árbol” o dendrograma) en lugar de devolver directamente un único particionado fijo. La idea es que puedas ver la estructura a varias escalas y decidir el número de clusters “cortando” el dendrograma. Muy utilizados en biología y genética.




Clustering Jerarquico

Hay dos enfoques para el agrupamiento jerárquico:


- **Aglomerativo** (AHC): parte de una fragmentación total de los datos y fusiona los datos progresivamente hasta que se obtiene un solo grupo. Aplica una estrategia bottom-up. Hablaremos de clustering o agrupamiento.
- **Divisivo** (DHC): parte de un único grupo y los divide de forma recursiva hasta conseguir un grupo para cada dato. Aplica una estrategia top-down. Hablaremos de segmentación.

Clustering Jerarquico




- Clustering **divisivo** (de arriba a abajo)
 - Empieza con todos los puntos en un único clúster (la raíz), luego:
 - Parte la raíz en un conjunto de clústers hijos, y sigue dividiendo recursivamente
 - Para cuando hay un único clúster por observación.
- Clustering **aglomerativo** (de abajo a arriba)
 - Cada observación es un clúster.
 - Se van fusionando clústers más similares en cada iteración.
 - Más estudiado que los divisivos.

Clustering Jerarquico



- El principal inconveniente de este tipo de algoritmos es que no es capaz de determinar el número de grupos a generar. Es necesario determinarlo previamente o fijar un criterio de parada en el proceso de construcción jerárquica.
- Se suele utilizar un diagrama denominado **dendograma** para representar las agrupaciones sucesivas que genera el algoritmo.





Clustering Jerarquico


El procedimiento básico del clustering jerárquico **aglomerativo** es el siguiente:

1. Cada observación se inicializa como un clúster.
2. En cada paso los dos clústeres más próximos se fusionan (métrica de distancia y criterio de enlace).
3. Se continua hasta todas las observaciones se agrupen en único clúster.

Clustering Jerarquico



Clustering Jerárquico




1) Jerárquico Aglomerativo (bottom-up)

Empieza con cada punto separado y va fusionando los clusters más cercanos.

Ejemplo con 6 puntos: A B C D E F

distancia (altura)



-----> (orden visual)

Ejemplo con 6 puntos: A B C D E F

Supongamos estas cercanías (para que haya una historia clara):

- A está muy cerca de B → distancia 1
- C está muy cerca de D → distancia 1
- E está muy cerca de F → distancia 1
- Los dos grupos {A,B} y {C,D} están a distancia 3
- El grupo {A,B,C,D} está a distancia 6 de {E,F}


Cómo obtener "K clusters" cortando el dendrograma

Imagina una línea horizontal de corte:

- Si cortas a altura 2 (entre 1 y 3):
- ves 3 clusters: {A,B}, {C,D}, {E,F}
- Si cortas a altura 4 (entre 3 y 6):
- ves 2 clusters: {A,B,C,D} y {E,F}

Eso es literalmente "cortar el árbol" a una altura.

Clustering Jerarquico



2) Divisivo (top-down): “se va cortando”

Empieza con todo en un solo cluster y lo divide.

distancia / “nivel de separación”

```
6 |           {A,B,C,D,E,F}
  |           /      \
3 |   {A,B,C,D}      {E,F}
  |   /      \      /  \
1 |   {A,B} {C,D} {E} {F}
  |   /  \   /  \
0 |   A   B C   D
-----> (orden visual)
```

Cómo leerlo


- La primera división (altura 6) separa lo más diferente: $\{A,B,C,D\}$ vs $\{E,F\}$.
- Luego (altura 3) divide $\{A,B,C,D\}$ en $\{A,B\}$ y $\{C,D\}$.
- Luego (altura 1) rompe las parejas en individuos.

“Cortar” el dendrograma para obtener K clusters


Igual que antes, pero ahora estás “mirando divisiones”:

- Si cortas a altura 4 (entre 3 y 6):
- obtienes 2 clusters: $\{A,B,C,D\}$ y $\{E,F\}$
- Si cortas a altura 2 (entre 1 y 3):
- obtienes 3 clusters: $\{A,B\}$, $\{C,D\}$, $\{E,F\}$

Clustering Jerarquico



Las **funciones de linkage** (criterios de enlace). Son la regla que define cómo medir la distancia entre dos clusters (no entre dos puntos) para decidir qué dos clusters se fusionan en cada paso del aglomerativo (o, equivalente, cómo se estructura el dendrograma).



Clustering Jerarquico

Linkage más comunes (aglomerativo)

1) single linkage (enlace simple)

Distancia entre clusters = la mínima distancia entre cualquier par de puntos (uno de cada cluster).

- Efecto: puede crear “cadenas” (chaining) si hay puntos puente.


$$d(C_i, C_j) = \min_{x \in C_i, y \in C_j} d(x, y)$$

2) complete linkage (enlace completo)

Distancia = la máxima distancia entre pares de puntos (uno de cada cluster).

- Efecto: tiende a clusters compactos; menos chaining.

$$d(C_i, C_j) = \max_{x \in C_i, y \in C_j} d(x, y)$$



Clustering Jerarquico

3) average linkage (enlace promedio)

Distancia = promedio de distancias entre todos los pares (uno de cada cluster).


- Efecto: compromiso entre single y complete.

$$d(C_i, C_j) = \frac{1}{|C_i||C_j|} \sum_{x \in C_i} \sum_{y \in C_j} d(x, y)$$

4) Ward

No usa "distancia entre clusters" como tal, sino que fusiona los clusters que menos aumentan la varianza intra-cluster (SSE).

- Efecto: suele dar clusters "redondos" (parecidos a K-Means).
- Importante: típicamente se usa con distancia euclídea.



Silhouette: k



El `silhouette_score` mide qué tan “bien” queda cada punto dentro de su cluster comparado con los clusters vecinos, y se usa mucho para elegir K (número de clusters) probando varios valores y quedándose con el que da mejor puntuación media.

Para cada punto i :

- $a(i)$: distancia media de i a los puntos de su propio cluster (cohesión).
- $b(i)$: la menor distancia media de i a los puntos de otro cluster (separación; el “cluster vecino” más cercano).

La silueta del punto es:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$



Gracias