


REGRESIÓN LINEAL

Regresión Lineal



$$\hat{Y} = a + bX$$

ESTADÍSTICA

Autor: Rubén Pérez González

Fecha: 09/11/2025

Asignatura: Sistemas de Aprendizaje Automático (IA)

1. Carga y Exploración de Datos


En esta fase inicial, se establecieron los cimientos del análisis importando las librerías fundamentales (pandas, numpy, seaborn) y cargando el conjunto de datos *Diabetes* desde la biblioteca scikit-learn. El objetivo principal fue transformar los datos brutos en una estructura manejable para verificar su calidad e integridad antes del modelado.

	age	sex	bmi	bp	s1	s2	s3	s4	s5	s6	target
0	0.038076	0.050680	0.061696	0.021872	-0.044223	-0.034821	-0.043401	-0.002592	0.019907	-0.017646	151.0
1	-0.001882	-0.044642	-0.051474	-0.026328	-0.008449	-0.019163	0.074412	-0.039493	-0.068332	-0.092204	75.0
2	0.085299	0.050680	0.044451	-0.005670	-0.045599	-0.034194	-0.032356	-0.002592	0.002861	-0.025930	141.0
3	-0.089063	-0.044642	-0.011595	-0.036656	0.012191	0.024991	-0.036038	0.034309	0.022688	-0.009362	206.0
4	0.005383	-0.044642	-0.036385	0.021872	0.003935	0.015596	0.008142	-0.002592	-0.031988	-0.046641	135.0

- **Dimensionalidad:** El dataset consta de **442 observaciones (pacientes)** y **11 variables**. Estas se dividen en 10 predictores fisiológicos (como age, sex, bmi, bp) y 1 variable objetivo (target), que cuantifica la progresión de la enfermedad.
- **Pre-escalado de Variables:** Un hallazgo crucial al observar las primeras filas es que los valores numéricos no están en sus unidades naturales. Variables como la edad (age) o el índice de masa corporal (bmi) presentan valores decimales pequeños (ej. 0.038076). Esto indica que el dataset ya viene **estandarizado**, lo cual es ventajoso ya que facilita la convergencia matemática del algoritmo de regresión.

2. Análisis Estadístico y Correlaciones

Para identificar qué variables fisiológicas tienen un impacto real en la progresión de la enfermedad, se realizó un análisis de correlación de Pearson. Este paso es fundamental para filtrar el "ruido" y detectar las señales predictivas más fuertes.



Para complementar la visualización y obtener una jerarquía precisa, se extrajeron los coeficientes numéricos exactos ordenados de mayor a menor impacto respecto a la variable *target*:

--- Variables más correlacionadas con el Target					
count	4.420000e+02	4.420000e+02	4.420000e+02	4.420000e+02	4.420000e+02
mean	-2.511817e-19	1.230790e-17	-2.245564e-16	-4.797570e-17	-1.381499e-17
std	4.761905e-02	4.761905e-02	4.761905e-02	4.761905e-02	4.761905e-02
min	-1.072256e-01	-4.464164e-02	-9.027530e-02	-1.123988e-01	-1.267807e-01
25%	-3.729927e-02	-4.464164e-02	-3.422907e-02	-3.665608e-02	-3.424784e-02
50%	5.383060e-03	-4.464164e-02	-7.283766e-03	-5.670422e-03	-4.320866e-03
75%	3.807591e-02	5.068012e-02	3.124802e-02	3.564379e-02	2.835801e-02
max	1.107267e-01	5.068012e-02	1.705552e-01	1.320436e-01	1.539137e-01
count	4.420000e+02	4.420000e+02	4.420000e+02	4.420000e+02	4.420000e+02
mean	3.918434e-17	-5.777179e-18	-9.042540e-18	9.293722e-17	1.130318e-17
std	4.761905e-02	4.761905e-02	4.761905e-02	4.761905e-02	4.761905e-02
min	-1.156131e-01	-1.023071e-01	-7.639450e-02	-1.260971e-01	-1.377672e-01
25%	-3.035840e-02	-3.511716e-02	-3.949338e-02	-3.324559e-02	-3.317903e-02
50%	-3.819065e-03	-6.584468e-03	-2.592262e-03	-1.947171e-03	-1.077698e-03
75%	2.984439e-02	2.931150e-02	3.430886e-02	3.243232e-02	2.791705e-02
max	1.987880e-01	1.811791e-01	1.852344e-01	1.335973e-01	1.356118e-01
target					
count	442.000000				
mean	152.133484				
std	77.093005				
min	25.000000				
25%	87.000000				
50%	140.500000				
75%	211.500000				
max	346.000000				

target	1.000000
bmi	0.586450
s5	0.565883
bp	0.441482
s4	0.430453
s6	0.382483
s1	0.212022
age	0.187889
s2	0.174054
sex	0.043062
s3	-0.394789
Name: target, dtype: float64	

Interpretación de Resultados: Al cruzar la información visual con los datos numéricos, observamos lo siguiente:


- Correlación Positiva Dominante:** El **BMI (Índice de Masa Corporal)** se confirma como el predictor individual más potente, con una correlación de **0.586**, seguido

muy de cerca por la variable **s5 (Lamotrigina)** con un **0.565**. Esto sugiere biológicamente que el peso y ciertos niveles séricos son determinantes clave.

- **Variables Secundarias:** La presión arterial (**bp**) y **s4** muestran una correlación moderada (en torno a 0.43 - 0.44), lo que indica que también aportan información valiosa al modelo.
- **Correlación Negativa:** Cabe destacar la variable **s3**, que presenta una correlación inversa considerable (**-0.394**). Esto significa que valores más altos de **s3** suelen asociarse con una menor progresión de la enfermedad.

3. Visualización de Relaciones Clave

Para confirmar las hipótesis estadísticas, analizamos visualmente la distribución de la variable objetivo y su relación con el predictor principal.



- **Histograma (Distribución):** La variable objetivo no sigue una distribución normal perfecta, pero es lo suficientemente acampanada y continua para permitir el uso de regresión lineal sin transformaciones complejas inmediatas.
- **Scatterplot (Linealidad):** El gráfico de dispersión confirma la tendencia: a medida que aumenta el BMI (eje X), aumenta la progresión de la enfermedad (eje Y). Aunque existe dispersión, la dirección de la pendiente es inequívocamente positiva.

4. Preprocesamiento

Para garantizar una evaluación honesta y evitar el sobreajuste (*overfitting*), se procedió con una estrategia de partición de datos estricta antes de entrenar nada.

Metodología:

- **Separación:** Se aislaron las características (X) de la variable objetivo (y).

- **Split (División):** Se aplicó un particionamiento *Hold-out* del 80-20.
 - **80% Entrenamiento:** Usado exclusivamente para calcular los coeficientes.
 - **20% Prueba:** Mantenido oculto al modelo para validar su capacidad de generalización ante datos nuevos.

```
Tamaño de X_train: (353, 10)
Tamaño de X_test: (89, 10)
```

5. Entrenamiento del Modelo de Regresión Lineal

Se entrenó el modelo utilizando el conjunto de entrenamiento. Al analizar los coeficientes resultantes, desciframos la "lógica interna" aprendida por el algoritmo:

- **Variables Dominantes:** El modelo asignó los pesos positivos más altos a **s5** y **BMI**, confirmándolos como los factores de riesgo principales.
- **Compensación Matemática:** Se observaron coeficientes opuestos y muy grandes para **s1** y **s2**. Dado que estas variables están muy correlacionadas, el modelo infla sus pesos en direcciones contrarias para equilibrar la ecuación, un efecto clásico de la multicolinealidad.

```
Intercepto (b0): 151.34560453985995

Coeficientes ordenados:
Variable Coeficiente
8      s5    736.198859
2      bmi    542.428759
5      s2    518.062277
3      bp     347.703844
7      s4     275.317902
6      s3     163.419983
9      s6      48.670657
0      age     37.904021
1      sex    -241.964362
4      s1    -931.488846
```

6. Evaluación del Modelo

Aplicamos el modelo sobre el conjunto de prueba (el 20% reservado) para cuantificar el error de predicción.

Tabla de Métricas:

- **MSE (Error Cuadrático Medio):** ~2900.19.
- **RMSE (Raíz del Error Cuadrático): 53.85.** Esta métrica indica que, en promedio, el modelo se equivoca por unos 54 puntos al predecir el nivel de progresión de la enfermedad.

- **R^2 (Coeficiente de Determinación): 0.45.**


Diagnóstico:

Un R^2 de 0.45 indica una capacidad predictiva moderada. El modelo explica el 45% de la variabilidad de los datos, lo cual es estadísticamente significativo pero sugiere que existen factores complejos en la enfermedad que escapan a una relación lineal simple con estas 10 variables.

MSE: 2900.19
RMSE: 53.85
MAE: 42.79
 R^2 : 0.4526

7. Visualización: Predicciones vs Realidad

Para validar visualmente el desempeño, graficamos los valores reales frente a los predichos.



- **Zona de Acierto:** La nube de puntos se agrupa razonablemente bien alrededor de la línea diagonal en los valores medios.
- **Desviaciones:** Se observa mayor dispersión en los extremos. El modelo tiende a perder precisión cuando la progresión de la enfermedad es muy baja o muy alta, sugiriendo la presencia de *outliers* o comportamientos no lineales en esos rangos.

8. Conclusiones Finales

Tras completar el ciclo de modelado, extraemos las siguientes conclusiones:

1. **Validación de Factores de Riesgo:** El estudio confirma cuantitativamente que el control del **Índice de Masa Corporal (BMI)** y los niveles séricos (**s5**) son críticos para estimar la evolución de la diabetes.
2. **Robustez del Modelo:** Aunque el modelo captura la tendencia general correctamente, la métrica R^2 (0.45) y el RMSE (54) evidencian que la Regresión Lineal es una aproximación útil pero limitada.
3. **Recomendación:** Para mejorar la precisión clínica en el futuro, se sugiere explorar modelos no lineales (como Random Forest) o incorporar más variables explicativas, ya que la relación actual deja más del 50% de la varianza sin explicar.